UNIVERSIDAD INTERNACIONAL DE LA RIOJA unir

Universidad Internacional de La Rioja

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos Masivos

Ciencia de datos como apoyo en la detección de enfermedades cardiovasculares

Trabajo Fin de Máster

Tipo de trabajo: Análisis de metodologías

Presentado por: Martínez Díez, Roberto

Director/a: Corbi Bellot, Alberto

Resumen

Las enfermedades cardiovasculares (ECV) son la principal causa de mortalidad a nivel mundial (el 30% de las muertes anuales en España se produce por ésta causa). En éste trabajo, basado en un dataset de registros médicos de pacientes y extraído del popular portal de retos de Machine Learning “Kaggle”, se estudian los factores de riesgo y el desenlace de padecer una ECV, y se han aplicado técnicas modernas de IA y Big Data. Además, mediante el uso del framework IBM-Watson Studio y herramientas como Python TensorFlow, Keras/Scikit-Learn, se han utilizado los algoritmos *Random Forest, GradientBoosting o Perceptrón multicapa* que permiten obtener una precisión en la clasificación del 92%, dato que mejora sensiblemente la mejor conseguida hasta la fecha. Finalmente se comparan IBM Watson con las herramientas Python con el fin de demostrar la facilidad de uso de uno y otro y los resultados obtenidos. Gracias al *Machine Learning* y el *Big Data* con el uso de herramientas de código abierto y privadas, se puede mejorar la predicción de este tipo de enfermedades, y salvar vidas en éste y otros campos de la medicina.

Palabras Clave: IBM-Watson, Big-Data, Predicción, Clasificación, Corazón.

Abstract

Cardiovascular diseases (CVD) are the main cause of mortality worldwide (30% of annual deaths in Spain are caused by this cause). In this work, based on a patients medical records dataset that has been obtained from the popular Machine Learning challenges portal “Kaggle”, the risk factors and outcome of suffering CVD are studied, and modern AI and Big Data techniques have been applied. In addition, through the use of the IBM-Watson Studio framework and tools such as Python TensorFlow, Keras / Scikit-Learn, the Random Forest, GradientBoosting or multilayer Perceptron algorithms have been used that allow obtaining a classification precision of 92%, a data that improves sensibly the best achieved to date. Finally, IBM Watson is compared with Python tools in order to demonstrate the ease of use of one and the other and the results obtained. Thanks to Machine Learning and Big Data with the use of open source and private tools, the prediction of this type of disease can be improved, and save lifes in this and other fields of medicine.

Keywords: IBM-Watson, Big-Data, Prediction, Classification, Heart

Índice de contenidos

1. Introducción 7

2. Las enfermedades cardiovasculares 10

2.1 Cardiopatías más frecuentes 10

2.2. Factores de riesgo cardiovascular 12

2.3 Tecnologías utilizadas en la actualidad 14

3. Ciencia de datos en la cardiología 16

3.1 Big data y aprendizaje automático 16

3.2 Contribuciones de la inteligencia artificial 18

4. Objetivos 21

4.1 Metodología 22

5. Material y métodos 23

5.1. Marco tecnológico 23

5.1.1 Herramientas utilizadas 24

IBM Watson Studio 24

Microsoft Excel 25

PyCharm / Jypiter Notebook 25

Python 25

TensorFlow 25

Keras 25

5.1.2 Algoritmos de Machine Learning 26

Random Forest 26

Support Vector Machines 27

Gradient boosting 27

5.1.3 Algoritmos de Deep Learning 28

Perceptrón Multicapa (MLP) 28

5.2. El dataset 29

5.2.2 Antecedentes de uso. 29

5.2.3 Exploración de las variables. 30

5.2.3 Correlación entre las variables. 39

5.2.4 Protección de datos RGPD 39

5.3. Detección de ECV con Machine Learning 40

5.3.1 Preparación del dataset 40

Ingeniería de características 40

5.3.2 Primer experimento: Random Forest 41

Importancia de las características *42*
Matriz de confusión *42*
5.3.3 Segundo experimento: Gradient Boosting 43
Importancia de las características *44*
Matriz de confusión *45*
5.3.2 Tercer experimento: Supported Vector Machines 45
Importancia de las características *46*
Matriz de confusión *46*
5.4. Detección de ECV con Deep Learning 47
5.4.1 Cuarto experimento: Perceptrón multicapa 47
5.5 Comparación de modelos Machine y Deep Learning 49
5.6. Detección de ECV con IBM Watson Studio 50
5.6.1. Configuración del proyecto 50
5.6.2. Preparación y análisis de los datos 51
5.6.3. Experimento de AutoAI de Machine Learning 53
Configuración del experimento *53*
Ejecución del experimento *54*
Interpretación de los resultados *55*
5.6.4. Experimento de SPSS Modeler (red neuronal) 57
Configuración del flujo de modelado *57*
Ejecución del flujo de modelado *58*
Evaluación de los resultados *58*
Importancia de las características *59*
6. Comparativa de las tecnologías utilizadas 60
6.1. Resultados obtenidos de ML y DL 60
6.2. Requisitos técnicos 61
6.3. Funcionalidad 62
6.3.1. IBM Watson Studio 62
Ventajas *62*
Inconvenientes *62*
6.3.2. Python con librerías de ML y DL 63
Ventajas *63*
Inconvenientes *63*
7. Conclusiones 64
7.1. Líneas de trabajo futuro 65
9. Bibliografía 66

Índice de ilustraciones

Figura 1. Causas de muerte en España por número de fallecidos en 2019-2020 (INE). 7
Figura 2. Diagrama de flujo de trabajo 8
Figura 3. Principales causas de muerte en España 2019 (INE). 10
Figura 4. Mortalidad por cardiopatías en la población española por cada 100.000 habitantes. 11
Figura 5. Popularidad búsquedas Google en el ámbito de la salud. (2014 - nov 2021) 16
Figura 6. Resonancia magnética (A) e identificación de ventrículos con Deep Learning (B) 17
Figura 7. Capacidades de Watson Studio 24
Figura 8. Clasificador Random Forest (elaboración propia) 26
Figura 9. Clasificador Gradient Boosting (elaboración propia) 27
Figura 10. Extracto del fichero heart.csv 29
Figura 11. Distribución de pacientes con ECV en función de la edad. 30
Figura 12. Proporción sanos y con ECV por sexo. 31
Figura 13. Distribución de valores de tipo de dolor de pecho 32
Figura 14. Distribución de la presión sanguínea de todos los pacientes 32
Figura 15. Distribución de niveles de colesterol entre los pacientes con ECV. 33
Figura 16. Distribución por sexo niveles de glucosa en enfermos de ECV. 34
Figura 17. Distribución de anomalías en la electrocardiografía, para pacientes con ECV. 35
Figura 18. Rangos de pulsaciones máximas por número de pacientes con ECV. 35
Figura 19. Proporción de personas con ECV con dolor de angina por ejercicio previo. 36
Figura 20. Distribución de elevación segmento ST en pacientes con enfermedad cardiaca. 37
Figura 21. Distribución de la forma Segmento ST en personas con ECV. 38
Figura 22. Proporción de pacientes con y sin ECV. 38
Figura 23. Correlación entre las variables independientes. 39
Figura 24. Resultado de aplicar ingeniería de variables 40
Figura 25. Random forest importancia de las variables clasificadoras 42
Figura 26. Matriz de confusión Random Forest 42
Figura 27. Gradient Boosting importancia de las variables clasificadoras 44
Figura 28. Matriz de confusión Gradient Boosting 45
Figura 29. Importancia de características en algoritmo Supported Vector Machines 46
Figura 30. Matriz de confusión de Supported Vector Machines 46
Figura 31. Keras tuner para crear un MLP configurable. 47
Figura 32. Comparación de precisiones obtenidas en función de técnicas aplicadas. 49
Figura 33. Tiempos de ejecución de los algoritmos de ML y DL 49
Figura 34. Panel de proyectos / activos de IBM Watson Studio 50
Figura 35. Información estadística de una variable en IBM Watson Studio 51
Figura 36. Histograma generado en IBM Watson a partir de característica del dataset 52
Figura 37. Creación de experimento, configuración y ejecución 53
Figura 38. Salida de IBM Watson tras la ejecución del experimento de clasificación 55

Figura 39. Detalle de importancia de características. 56
Figura 40. Matriz de confusión tras ejecución del experimento AI. 56
Figura 41. Configuración de flujo de modelado para clasificar con red neuronal 57
Figura 42. Matriz de confusión perceptrón IBM Watson Studio 58
Figura 43. Importancia características Perceptron IBM Watson Studio 59

Índice de tablas

Tabla 1. Tecnologías aplicadas en la actualidad a la cardiología. 15
Tabla 2. Contribuciones relevantes de la IA en la cardiología. 19
Tabla 3. Análisis de los datos de edad. 31
Tabla 4. Análisis de los datos de presión sanguínea en reposo. 33
Tabla 5. Análisis de los datos de colesterol. 34
Tabla 6. Análisis valores de pulsaciones máximas 36
Tabla 7. Análisis de los valores de OldPeak 37
Tabla 8. Valores obtenidos de precisión de Random forest sin y con optimización de Optuna 41
Tabla 9. Precisión de Gradient boosting con y sin optimización de hiperparámetros con Optuna. 44
Tabla 10. Precisión de SVM sin y con optimización de hiperparámetros con Optuna 45
Tabla 11. Comparación de resultados perceptrón con y sin optimización de parámetros. 48
Tabla 12. Parámetros perceptron multicapa IBM Watson Studio 59
Tabla 13. Comparativa de precisión y tiempo de ejecución de algoritmos 60
Tabla 14. Comparación de requisitos IBM Watson vs Python TensorFlow/Keras 61

1. Introducción

Las enfermedades cardiovasculares (ECV) representan todas aquellas relativas al corazón y a los vasos sanguíneos, y son la causa con más mortalidad en España, tal como se muestra en la Figura 1. La cardiopatía coronaria es el tipo más común, y está relacionada con la acumulación de grasa en las arterias que entran al corazón, su desenlace es un ataque cardíaco. También la insuficiencia cardiaca (falta de bombeo), las arritmias (sistema eléctrico del corazón), las relativas a las válvulas del corazón (soplos) y la hipertensión, son enfermedades que pueden provocar en menor o mayor medida un desenlace fatal (Toche, 2021).

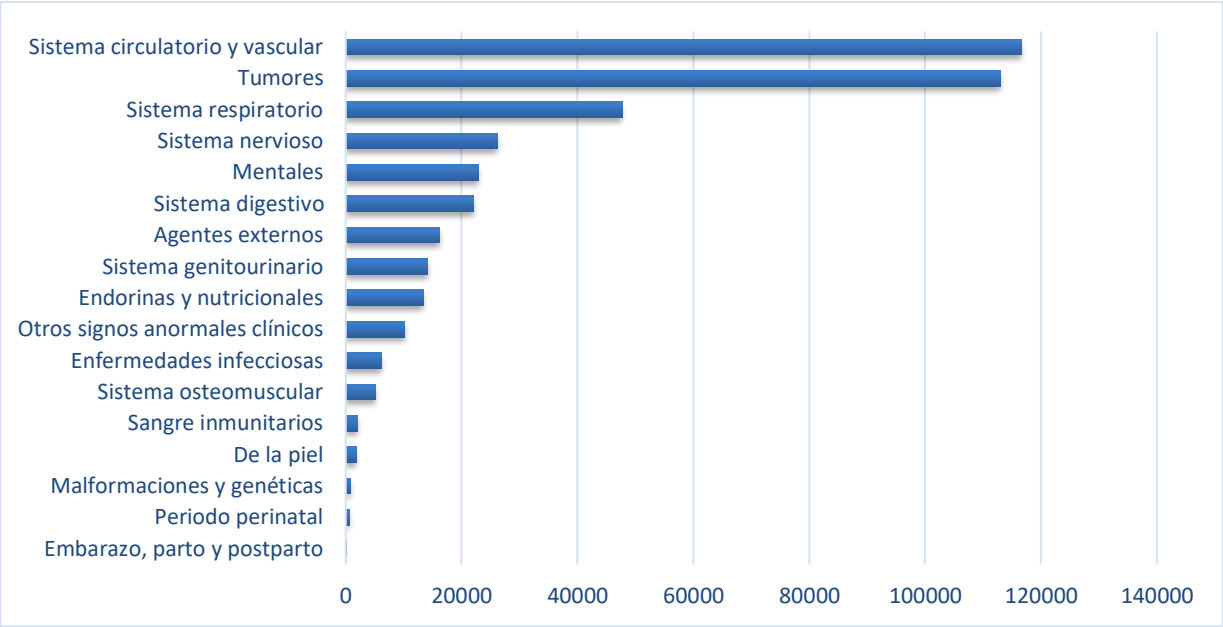

Figura 1. Causas de muerte en España por número de fallecidos en 2019-2020 (INE[1]).

Tanto el Big Data como el Machine Learning (ML) se aplican hoy en día a la medicina con resultados muy prometedores y en particular a la cardiología, gracias a que existen éstas y otras realidades tecnológicas que son de uso imprescindible en la actualidad, por ejemplo:

- La computación de alto rendimiento (HPC) que usa el procesamiento paralelo para ejecutar aplicaciones avanzadas rápida y eficientemente.
- La aparición de centros de supercomputación en el mundo.
- Los servicios en la nube y la informática móvil.

[1] Fuente: https://www.ine.es/jaxiT3/Datos.htm?t=7947#!tabs-grafico

Además, la incorporación de las historias clínicas electrónicas permiten la mejora de las predicciones usando las citadas tecnologías, en base a grupos definidos por expertos médicos, cosa que hasta hoy no se solía hacer (Prohías, 2021). En éste trabajo, se hace una breve exposición de las tecnologías utilizadas para la ayuda en la detección de las enfermedades cardiovasculares mostrando qué soluciones existen, cuáles se aplican y que beneficios aportan. Posteriormente se realiza un análisis descriptivo del conjunto de datos donde se muestran las estadísticas de los citados factores y las relaciones existentes entre los mismos. Después de esto, se elaboran modelos de inteligencia artificial basados en diferentes algoritmos, para poder predecir y clasificar nuevos casos de ECV en base a los registros de factores de riesgo del dataset y después se hace una comparación entre ellos.

Las técnicas de ML más adecuadas para este tipo de problemas de clasificación son las basadas en árboles y en redes neuronales, ambas se encuentran encuadradas en el aprendizaje supervisado. Por otro lado, también se plantean dos visiones fundamentadas en el uso de distintas tecnologías de análisis y ciencia de datos. Por un lado el uso del framework IBM Watson Studio, y por otro la utilización de Python como lenguaje de procesamiento, utilizado comúnmente por analistas y científicos de datos para el estudio, entrenamiento y visualización de los datos.

Con la idea de mostrar las capacidades de IBM Watson Studio respecto al desarrollo de técnicas de IA en Python, se realiza una comparación analizando la dificultad de uso por personal no experto en ciencia de datos, ejecutando sus herramientas de ML y comparando los resultados de precisión y velocidad. El flujo de trabajo se muestra en la Figura 2.

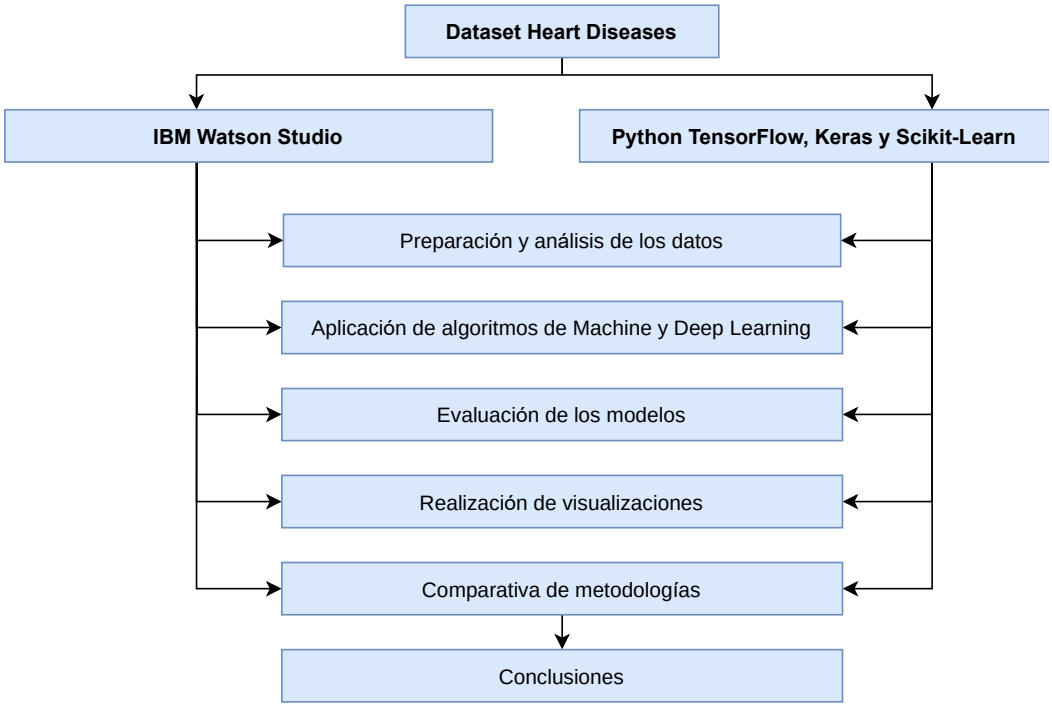

Figura 2. Diagrama de flujo de trabajo

A continuación se detalla la estructura capitular en la que, a partir de éste punto, se organizará el trabajo:

- En el **capítulo *2*** se hace una introducción a las enfermedades cardiovasculares así como a los factores principales de riesgo, y una breve referencia al marco tecnológico actual relativo a la cardiología.
- En el **capítulo 3,** se hace una exposición del uso Big Data y la Inteligencia artificial aplicados a la cardiología como herramientas de ayuda a la toma de decisiones médicas, así como de las enfermedades sobre las que más se aplican las diferentes técnicas.
- En el **capítulo 4** se fijan los objetivos del trabajo, especificando los métodos usados en ambos frameworks para alcanzar los resultados y que permiten realizar una comparativa a varios niveles, ya sea por eficacia, eficiencia, usabilidad y capacidad técnica.
- En el **capítulo 5***,* se realiza la descripción de los datos analizando cada factor de riesgo, y se muestran los pasos seguidos en cada framework para la obtención de resultados aplicando algoritmos de Machine Learning y Deep Learning y los procesos de ingeniería de variables y optimización.
- En el **capítulo 6,** se elabora un análisis comparativo de las herramientas utilizadas, mostrando la complejidad y ventajas de usar uno u otro sistema. Además se presentan los requisitos técnicos necesarios para utilizar tanto IBM Watson como las herramientas de desarrollo de Python, y se crean visualizaciones de los datos a partir de ambos frameworks, mostrando, comparativamente, la adecuación a los roles de analistas y científicos de datos, así como a los posibles interesados de un entorno médico.
- En el **capítulo 7***,* se exponen las conclusiones obtenidas tras el uso de las herramientas y el análisis de los datos, teniendo en cuenta aplicabilidad de cada metodología en distintos entornos en función de las necesidades y capacidades del ecosistema Big Data de que se disponga en una determinada organización.

2. Las enfermedades cardiovasculares

La primera causa de muerte en España[2], de la Unión Europea[3] y del resto del mundo durante los últimos años y exceptuando los meses desde abril del año 2020 por las muertes debido al Covid-19, son las enfermedades relacionadas con el sistema circulatorio, entre las que se encuentran los accidentes vasculares, isquemias, insuficiencias cardiacas, infartos...etc., tal como se puede observar en la siguiente Figura 3.

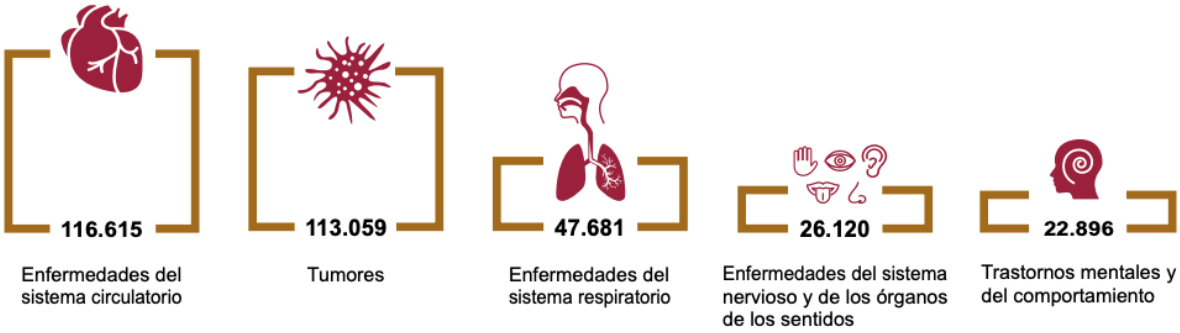

Figura 3. Principales causas de muerte en España 2019 (INE[4]).

Las enfermedades cardiovasculares (González, 2021), son aquellas que afectan al corazón y a los vasos sanguíneos. Se presentan muchas veces sin dolor y sin síntomas evidentes, por ello a veces, no son tratadas por los especialistas adecuados. Cada enfermedad afecta de diferente forma al sistema vascular y al corazón.

2.1 Cardiopatías más frecuentes

De entre todas las enfermedades cardiovasculares, las que se indican a continuación son las que tienen mayor incidencia entre la población y además son las de más mortalidad (Oen-Hsiao, 2019).

- **Insuficiencia cardiaca**: Producida por un desequilibrio entre la capacidad del corazón de bombear sangre, y las necesidades del organismo.

[2] https://www.ine.es/mapas/svg/indicadoresDefuncionCausa.htm
[3] https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Cardiovascular_diseases_statistics
[4] https://www.ine.es/infografias/infografia_causas_muerte.pdf

- **Hipertensión arterial**: Esta enfermedad aumenta el riesgo de tener un ataque al corazón, y se produce por un estrechamiento de arterias pequeñas, llamadas arteriolas, encargadas de regular el flujo sanguíneo. Al hacerse pequeñas el corazón debe esforzarse más para hacer fluir la sangre, y por tanto aumenta la presión en los vasos sanguíneos.
- **Colesterol**: Mediante una analítica de sangre podemos ver si tenemos el colesterol alto, sobre todo el "malo", además no produce síntomas hasta que se sienten resentidos los vasos sanguíneos y el corazón.
- **Infarto de miocardio**: Se puede producir por la obstrucción de una arteria, lo cual, provoca una disminución de oxígeno a las células del corazón, provocando la muerte de éstas y haciendo que se destruya parte del músculo cardiaco. El síntoma más común es un dolor agudo en el pecho.
- **Angina de pecho**: Se produce cuando la sangre necesaria en el corazón no fluye, es debido a la obstrucción de las arterias coronarias. El síntoma principal es que el paciente sufre una fuerte presión en el pecho.
- **Trastornos del ritmo cardiaco**: Consisten en la alteración de la frecuencia o regularidad normal del pulso de una persona, se denominan arritmias. Aunque puede ser frecuente entre la población, dependiendo del grado y tipo, si se puede considerar enfermedad cardiovascular. Estos trastornos normalmente son consecuencia de una enfermedad cardiovascular subyacente.

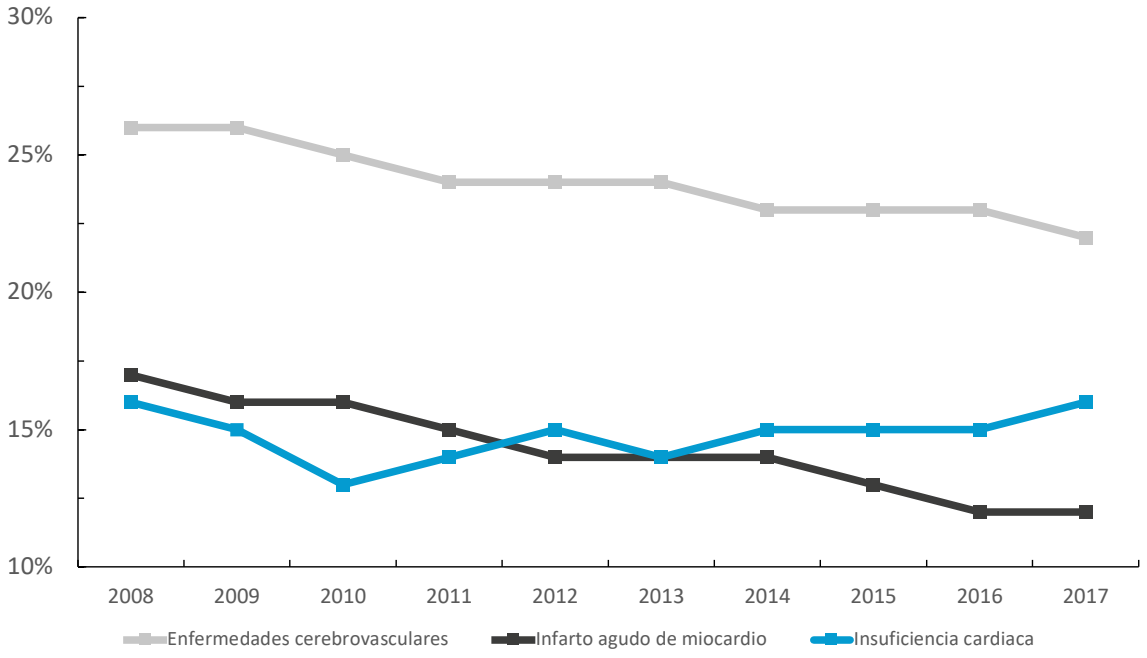

Figura 4. Mortalidad por cardiopatías en la población española por cada 100.000 habitantes[5].

[5] Fuente: https://fundaciondelcorazon.com/images/mortalidad-cardiovascular-2017.pdf

Aunque la tasa de mortalidad relacionada con enfermedades cardiovasculares en términos absolutos ha descendido en los últimos años, sigue siendo la primera causa de mortalidad en España, y la cardiopatía de insuficiencia cardiaca, tal y como se muestra en la Figura 4, no consigue reducir la mortalidad en términos relativos.

2.2. Factores de riesgo cardiovascular

Para el estudio y predicción de la enfermedades cardiovasculares, como las indicadas en el punto anterior, se deben tener en cuenta diferentes condiciones de salud, estilo de vida, edad e historial familiar que pueden incrementar el riesgo de padecerlas. Se denominan "factores de riesgo" y algunos no pueden ser controlados (por ejemplo hereditarios y la edad), en cambio otros sí. La hipertensión es un factor peligroso, ya que afecta al sistema vascular, al corazón y al resto de órganos como pueden ser los riñones y el cerebro. Los niveles anormales de colesterol en sangre dificultan la fluidez sanguínea a través de arterias y venas, pero lo peor es que normalmente su anomalía no presenta síntomas. La diabetes, provocada por la falta de insulina para procesar los azúcares en sangre, y que se encarga de generar el páncreas, provoca altos niveles de azúcar en sangre, lo cual daña los vasos sanguíneos y los nervios que controlan el corazón.

Por otro lado, la obesidad o exceso de grasa está asociada al colesterol "malo" y a niveles altos de triglicéridos. Además la obesidad puede provocar hipertensión y diabetes. Los factores de riesgo más representativos son:

- **Edad**: Tiene un efecto notable sobre el corazón y el sistema arterial, lo que lleva a un aumento de las enfermedades cardiovasculares que incluyen aterosclerosis, hipertensión, infarto de miocardio y accidente cerebrovascular. Los tejidos cardiovasculares envejecidos se ejemplifican mediante alteraciones patológicas que incluyen hipertrofia, función diastólica del ventrículo izquierdo (VI) alterada y capacidad inversa sistólica disminuida, rigidez arterial aumentada y función endotelial[6] deteriorada (North, 2012).

- **Género**: La edad, la hipertensión, el colesterol total y el colesterol unido a *lipoproteínas de baja densidad* (LDL) tienen una gran influencia en los hombres (Zujie, 2019). Pero el tabaquismo, la diabetes, los triglicéridos y los niveles de colesterol unido a *lipoproteínas de alta densidad* (HDL) afectan principalmente a las mujeres.

[6] http://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S1405-99402006000600022

- **Dolor de pecho**: La angina de pecho o angina típica es el malestar que se nota cuando el corazón no recibe suficiente sangre u oxígeno. Así como se refleja en el documento "Typical and Atypical Angina" (Tumolo, 2015), esto se debe a un bloqueo o acumulación de placa en las arterias coronarias. Si una o más de las arterias coronarias están parcial o totalmente obstruidas, el corazón no recibirá suficiente oxígeno. Los hombres suelen tener el tipo habitual de angina descrito anteriormente, pero las mujeres pueden tener una presentación más sutil llamada angina atípica.

- **Obesidad**: La prevalencia de la obesidad, definida por el índice de masa muscular (IMC) como factor de riesgo, se ha triplicado entre 1975 y 2016, en concreto afecta a un 11% de hombres y a un 15% de mujeres. Ahora hay más gente obesa que con falta de peso, y esto ha sido causado por la globalización, la rápida urbanización y el incremento de la oferta alimenticia con exceso de calorías. Partiendo de un IMC de 25 kg/m2, cada incremento 1 kg/m2 está asociado a un incremento del 5% de riesgo de muerte por enfermedad cardiovascular entre la población Europea (Kotsis, y otros, 2018).

- **Presión sanguínea en reposo:** La presión arterial es la fuerza contra las paredes de las arterias cuando el corazón bombea sangre por todo el cuerpo. Tal y como se indica en el artículo "How blood presure affects heart disease" (Mill, 2016), a medida que envejecemos, aumenta nuestro riesgo de hipertensión arterial. Más del 76% de los hombres de más de 75 años la padecen, y casi el 80% de las mujeres tienen presión arterial alta cuando llegan a los 75 años.

- **Colesterol**: El colesterol es una sustancia cerosa parecida a la grasa, producida por el hígado y que se encuentra en ciertos alimentos. Cuando hay demasiado colesterol en la sangre, se acumula en las paredes de las arterias disminuyendo o bloqueando el flujo y provoca un proceso llamado aterosclerosis, una forma de enfermedad cardíaca. La sangre transporta oxígeno al corazón y, si no llega suficiente sangre y oxígeno a su corazón, puede sufrir dolor en el pecho. Si el suministro de sangre a una parte del corazón se interrumpe por completo debido a un bloqueo, el resultado es un ataque cardíaco (Beckerman, 2020).

- **Diabetes / Glucemia en ayunas**: Tanto el nivel bajo de glucosa como la glucosa en ayunas alterada se consideran predictores del riesgo de accidente cerebrovascular y enfermedad coronaria. En el 75% de los diabéticos de tipo II, la causa de mortalidad principal es enfermedad cardiovascular (Millaruelo Trillo, 2002). En ayunas, los niveles altos (+120 mg/dl) disparan el riesgo de contraer una enfermedad cardiovascular, y es un claro síntoma de diabetes (Park, y otros, 1988–1993).

- **Electrocardiograma en reposo**: La electrocardiografía, representa la variación del voltaje entre contracciones cardiacas a lo largo del tiempo. Cuando se observan cambios anormales en ciertas partes de la gráfica que representa el latido cardiaco, éstos indican diferentes enfermedades relacionadas con diferentes partes del corazón (Ginghina, Ungureanu, Vladaia, Popescu, & Jurcut, 2009).

- **Pulsaciones máximas en reposo**: La muerte por ECV, aumenta un 14% por cada 10 ppm de frecuencia cardiaca sobre la normal, y que es independiente de la edad, capacidad deportiva, presión sanguínea o índice de masa corporal (Okamoto & Hori, 2012).

- **Ejercicio extremo:** El entrenamiento crónico con ejercicio extremo y la competencia en eventos de resistencia pueden provocar daños y trastornos del ritmo cardiaco. Las personas con factores de riesgo genéticos son especialmente vulnerables. Existen estudios que determinan que, incluso después de terminar las carreras extremas, las muestras de sangre de los atletas contienen biomarcadores asociados con daño cardíaco (Mateos-Cáceres, 2009).

2.3 Tecnologías utilizadas en la actualidad

Para la medición, control y análisis de determinados factores de riesgo, la ciencia y la tecnología han puesto al alcance de pacientes y médicos distintas soluciones. Desde la implantación del primer marcapasos allá por el año 1958, la tecnología usada en medicina cardiovascular ha ido evolucionando hasta llegar a complejos sistemas que son usados para la cirujía y la detección/prevención de enfermedades cardiovasculares.

A continuación se muestra una relación de las técnicas y dispositivos más innovadores (Tabla 1), cuya utilización es cada vez más frecuente y que sirven de ayuda, por un lado a pacientes para controlar aspectos fisiológicos (tensión arterial, estrés…etc.), y por otro a los cardiólogos como herramientas de apoyo para la toma de decisiones médicas.

Tabla 1. Tecnologías aplicadas en la actualidad a la cardiología.

Tecnología	Descripción	Beneficios en cardiología
Wearables de monitorización cardiaca	Smart-Clothes con sensores corporales o smartwatches tipo FitBit o Apple Watch unidos a Apps móviles, permiten monitorizar el pulso cardiaco o la presión arterial y detectar anomalías, en base al software que analiza los datos medidos en la muñeca del paciente.	• Mejora en la rehabilitación monitorizando el pulso. • Detección de arritmias y anticipación de fallos cardiacos. • En algunos casos también realizan electrocardiografías.
Realidad virtual (VR) y aumentada (AR)	Es un casco de realidad aumentada que superpone y registra un conjunto de datos en un paciente en la mesa de quirófano. Permite cortar virtualmente al paciente para planificar el procedimiento y marcar su piel para las incisiones en función de la capacidad de los tejidos subyacentes.	• Aceleración de la transferencia de conocimientos prácticos. Análisis de imágenes de tomografía de coherencia óptica (OCT)[7] • Examen de lesiones y segmentos vasculares de forma virtual y holográfica para el preoperatorio.
Sistemas de navegación robotizada por catéter	Son sistemas operados remotamente con precisión milimétrica, para intervenciones coronarias percutáneas y en casos vasculares periféricos.	• Intervención de oclusiones totales crónicas (CTO) de sistemas vasculares[8].
Tecnología virtual de reserva de flujo fraccional (FFR- CT)	Se trata de un sistema de toma de imágenes en base a la reacción de un fluido inyectado en el paciente que realiza una reconstrucción en 3D de los sistemas vasculares.	• Detección de la necesidad de un stent en una lesión coronaria[9]
Big Data de información estructurada	Hace uso de la *Data-Mining* sobre grandes volúmenes de datos relativos a registros electrónicos médicos de pacientes, existentes en los hospitales.	• El análisis de factores de riesgo y el desenlace en otros pacientes, ayudan a la detección precoz y prevención de ECV.
Inteligencia artificial (IA)	Basada en la aplicación y entrenamiento de algoritmos de *Machine Learning* (ML) o *Deep Learning* (DL) con información fisiológica obtenida en tiempo real de dispositivos como smart-clothes, wearables, sensores, escáneres y en distintos formatos como ultrasonidos, imágenes, radiología, electrocardiografías o historiales médicos. Se utilizan algoritmos de aprendizaje supervisado como redes neuronales, o no supervisado (clustering).	• Identificación de patrones que coinciden con los datos existentes de los que ya "aprendieron" y hacer predicciones. • Descubrimiento de patrones nuevos no lineales para descubrir información oculta, especialmente en el análisis de imágenes. • Complementación del conocimiento de médicos.

Fuente: https://www.dicardiology.com/content/blogs/8-cardiovascular-technologies-watch-2020

[7] https://www.dicardiology.com/videos/video-use-virtual-reality-aid-congenital-heart-disease
[8] https://www.dicardiology.com/videos/video-first-robotic-pci-case-germany-robocath-r-one-system
[9] https://www.dicardiology.com/videos/video-using-ffr-ct-everyday-practice

3. Ciencia de datos en la cardiología

Tanto el *Big Data* como la *Inteligencia Artificial*, son tecnologías que están en pleno auge y, desde hace poco tiempo, el creciente interés en el ámbito de la salud tal como se muestra en la Figura 5, denota los esfuerzos que se están haciendo por utilizarlas en la medicina y en particular en la cardiología. La motivación principal para usar éstas tecnologías es la de mejorar aspectos relacionados con la detección precoz, seguimiento e investigación de diversas enfermedades cardiovasculares para facilitar la toma de decisiones médicas.

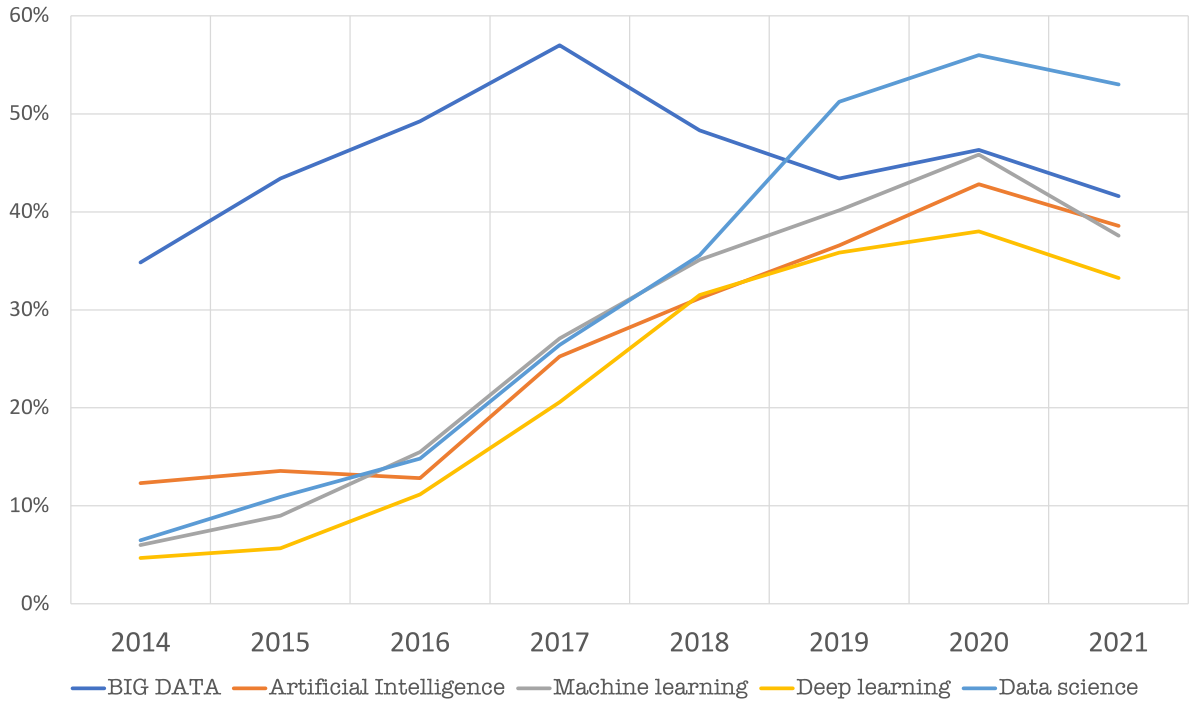

Figura 5. Popularidad búsquedas Google en el ámbito de la salud. (2014 - nov 2021)[10]

3.1 Big data y aprendizaje automático

Los términos de Big Data e Inteligencia artificial no son lo mismo aunque su uso está relacionado dentro de la ciencia de datos. Cuando hablamos de almacenar o gestionar el origen de los datos, así como su extracción, transformación u homogeneización, estamos dentro del ámbito de Big Data, donde grandes volúmenes de datos de diferente naturaleza y

[10] Fuente: Google Trends

tipo, son generados por diferentes sistemas médicos, y que son de gran utilidad al usarse dentro de un marco colaborativo entre las instituciones médicas. El Machine Learning (ML) como parte de la inteligencia artificial (IA) comprende sistemas que aprenden automáticamente de esos datos sin la necesidad de la intervención humana de forma que, tras el entrenamiento recurrente de algoritmos con datos históricos de pacientes, son capaces de proveer información valiosa a los cardiólogos (Dilsizian SE, 2014).

Por otro lado, el aprendizaje profundo (Deep Learning) es el campo que en la actualidad está avanzando a mayor velocidad, y por ello es de gran interés para la cardiología. Su aplicación en el análisis de imágenes cardiológicas, ayuda a los médicos en la tediosa tarea que supone visualizarlas y analizarlas una a una. Para automatizar esta labor, se usa el tratamiento de imágenes basado en el uso de Redes Neuronales.

En la actualidad, las más utilizadas para éste cometido son las Redes Neuronales Convolucionales (CNN) y las Redes Neuronales Recursivas (RNN). El empleo de éstas técnicas a nivel cardiológico requiere la revisión de ciertos aspectos que son necesarios de cara a preparar un escenario idóneo para el análisis. Aspectos que pasan por segmentar e identificar las distintas estructuras del corazón y clasificar las imágenes asociadas a distintas afecciones, aunque también es posible el uso de imágenes artificiales hiperrealistas, generadas por expertos en modelados 2D y 3D de la mano de cardiólogos (Christian F. Baumgartner, 2017). La aplicación de Deep Learning con redes neuronales, tal y como se muestra en la Figura 6, permite la identificación automática del ventrículo izquierdo y derecho, partiendo de imágenes de resonancia (A), la red neuronal es capaz de identificar y segmentar los ventrículos (B).

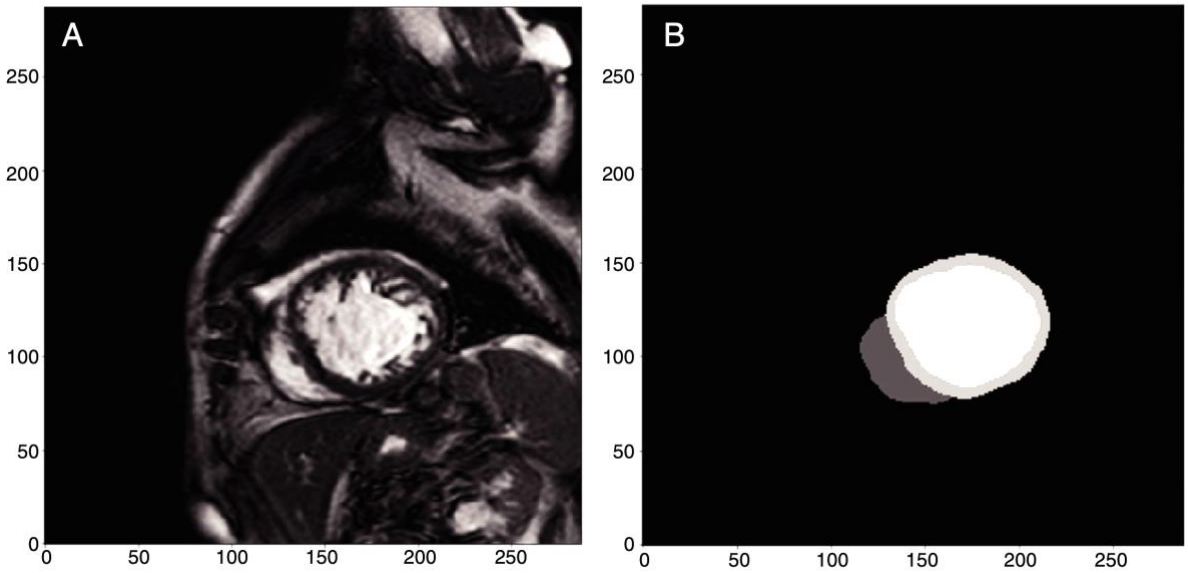

Figura 6. Resonancia magnética (A) e identificación de ventrículos con Deep Learning (B)[11]

[11] Fuente: https://www.revespcardiol.org/es-pdf-S0300893219302507

Los modelos resultantes de aplicar estas tecnologías requieren de gran cantidad de datos y este volumen de información, presente en los diferentes sistemas médicos, hoy en día es limitado. En la actualidad, la recolección y adaptación de los datos médicos está empezando a implantarse y su adecuación a la legislación y ética, así como los escasos estudios en determinadas enfermedades, hacen que todavía no se pueda explotar todo el potencial de la IA en el ámbito cardiológico (Char, Shah, & Magnus, 2018).

Otra limitación importante es la interpretabilidad de los modelos de ML y DL. Los datos de salida de dichos modelos nos muestra la importancia de ciertos predictores, pero no explicaciones biológicas, aunque es cierto que existen metodologías que permiten interpretar y analizar los pesos de los parámetros o variables médicas para poder obtener una explicación individualizada de cada predicción.

En conclusión, todavía no es posible saber de forma clara, por qué los modelos de ML y DL más complejos toman una determinada decisión, cosa que puede dificultar la generación de conocimiento y su aplicabilidad a la medicina (Irene, Sebastian, Wojciech, & Robert, 2016).

3.2 Contribuciones de la inteligencia artificial

Algunos de los trabajos realizados en el área de la cardiología, han sido promovidos en conferencias médicas, donde algunos expertos han aplicado sus conocimientos en cardiología para resolver muchas cuestiones planteadas, y otros parten de la necesidad de resolver diferentes problemas existentes en instituciones médicas, mediante la recolección de datos de pacientes para su estudio. De entre todas las enfermedades cardiovasculares, las siguientes son las que han recibido mayor foco en cuanto a la aplicación de técnicas de IA:

- **Arritmias cardiacas**: El uso de machine learning para la predicción es muy adecuado, ya que gran número de estudios abordan modelos predictivos de aparición de fibrilación auricular proxística por su significación en esta cardiopatía. Además, el aprendizaje supervisado sobre variables significativas con algoritmos de clasificación, ha permitido la mejora en la gestión de alarmas de telemonitorización cardiaca. También la aplicación de Deep Learning sobre imágenes o gráficas de electrocardiografías han dado buenos resultados (Elias, y otros, 2018).
- **Cardiopatía isquémica**: La aplicación de IA a los historiales médicos electrónicos, provenientes de atención primaria médica de la población general, se ha revelado especialmente útil respecto a las escalas de riesgo usadas tradicionalmente. La predicción de la mortalidad a enfermos con infarto, con síndrome coronario, sobre registros de

hospitales individuales o registros como el SWEDEHEART[12] utilizando el aprendizaje supervisado, han demostrado la necesidad de disponer muestras grandes de datos para obtener mejores resultados (Shouval, y otros, 2017).

- **Insuficiencia cardiaca**: El aporte de la IA sobre este caso se centra el la optimización de los ingresos hospitalarios. Es un enfoque diferente, ya que está orientado a la optimización en la medición y gestión de otros sistemas como sistemas de alerta, evaluación para la hospitalización…etc. Un buen ejemplo de la combinación de Machine y Deep Learning en este campo es la clasificación de la función diastólica analizando electrocardiografías (Sanchez-Martinez, y otros, 2018). Esto junto con el uso de redes neuronales, han confirmado que se puede estandarizar e interpretar enfermedades complejas, y ayudar a la toma de decisiones (Lancaster, y otros, 2019).

Tal como se observa en la Tabla 2, algunas contribuciones han obtenido en la mayoría de los casos, resultados positivos para el mejor conocimiento de las cardiopatías.

Tabla 2. Contribuciones relevantes de la IA en la cardiología.

Referencia	Área / Aplicación	Técnica IA	Método	Resultado
(Ebrahimzadeh, y otros, 2018)	**Arritmias** / Predicción de Fibrilación auricular (FA) paroxística a partir de frec. Cardiaca	Aprendizaje supervisado	Análisis de 106 señales de 53 electrocardiografías con KNN, SVM, RN	Sensibilidad=100%, Especificidad=95%, Exactitud=98%
(Budzianowski, y otros, 2019)	**Arritmias** / Predicción de recurrencia FA tras crioablación de venas pulmonares	Aprendizaje supervisado	Análisis de 118 pacientes con 56 señales clínicas con GB, SVM, sobremuestreo	Identificación de 7 predictores en concordancia con análisis estadístico univariante.
(Yıldırım, Pławiak, Tan, & Acharya, 2018)	**Arritmias** / Detección de hasta 17 tipos de arritmias a partir de ECG	Aprendizaje supervisado	Análisis de 1000 señales de ECG de la BBDD MIT-BIH. Usando CNN	Precisión del 91%
(Weng, Reps, Kai, Garibaldi, & Qureshi, 2017)	**Riesgo cardiovascular** / Predicción de eventos cardiacos a 10 años partiendo de historial clínico	Aprendizaje supervisado	Análisis de 378.256 registros electrónicos de individuos, con prescripciones médicas y tests. Se usó RF, RL, GB y RN	Área bajo la curva del mejor algoritmo (RN) igual a 0,76.

[12] https://heart.bmj.com/content/96/20/1617

Referencia	Área / Aplicación	Técnica IA	Método	Resultado
(Wallert, 2017)	**Cardiopatía isquémica** / Predicción de supervivencia a 2 años tras infarto de miocardio a partir de datos poblacionales, clínicos y eco	Aprendizaje supervisado	Registro SWEDEHEART de 51.943 pacientes y 54 variables. Algoritmos SVM, LR, RF	Área bajo la curva del mejor algoritmo igual a 0,84. Identificación de variables predictoras
(Medved, y otros, 2018)	**Insuficiencia cardiaca** / Predicción del diagnostico en pacientes en lista de espera de transplante de corazón	Aprendizaje supervisado	Registro UNOS (United Network Organ Sharing) de 27.444 pacientes. Algoritmo RN.	Precisión de 0,680 para predicciones a 365 y 730 días vista.
(Inan, y otros, 2018)	**Insuficiencia cardiaca** / Seguimiento remoto de pacientes para el ajuste de tratamiento y evitar hospitalización monitoreando señal ECG con wearables	Aprendizaje no supervisado	Análisis de 45 pacientes. Se usa Graph Similarity Score	Diferencias significativas entre grupos (compensados frente a descompensados)
(Sanchez-Martinez, y otros, 2018)	**Insuficiencia cardiaca** / Caracterización de la insuficiencia con eyección conservada a partir de ecocardiografía	Aprendizaje no supervisado	Análisis de 56 pacientes con 22 variables. Se usó Clustering.	El 71% de verdaderos positivos.
(Ahmad, y otros, 2018)	**Insuficiencia cardiaca** / Predicción de la evolución y fenotipado de pacientes	Aprendizaje supervisado y no supervisado	Análisis de datos demográficos, clínicos y farmacológicos de 44.886 pacientes. Se usó RF, Cluster analysis	Identificación de 4 fenotipos con diferencia significativa en evolución y respuesta terapéutica
(Tesche, Cecco, & Baumann, 2018)	**Imagen cardiaca** / Cálculo de la reserva fraccional de flujo a partir de imágenes de tomografía coronaria	Aprendizaje supervisado	Análisis de TC coronario de 85 pacientes. Se usó SVM.	Sensibilidad 79%, Especificidad 93%.

Fuente: https://www.revespcardiol.org/es-pdf-S0300893219302507

4. Objetivos

El objetivo general de este trabajo es proponer una herramienta de apoyo médico, que permita predecir una enfermedad cardiovascular en base a la combinación de los datos asociados a los factores de riesgo, recogidos en un conjunto de datos, y que significan el padecimiento en una ECV. Para alcanzarlo, se realiza el estudio de algunas técnicas de IA y Big Data aplicadas a la cardiología y se tendrán en cuenta los resultados obtenidos con anterioridad por otros investigadores. Se hará una introducción a los algoritmos más utilizados en las enfermedades cardiovasculares con mayor incidencia. Así mismo se hará uso por un lado, del framework IBM Watson Studio, y por otro lado del paquete de herramientas de Python TensorFlow, Keras y Scikit-Learn. Con el fín de obtener conclusiones sobre ambas plataformas, se evaluarán los procedimientos y los resultados obtenidos, y se plantearán las ventajas e inconvenientes que supone usar cada una de ellas. De forma más específica, los objetivos consistirán en la realización de distintas tareas las cuales se detallan a continuación:

- Investigar los factores biológicos que influyen comúnmente en una enfermedad cardiovascular, explicando la importancia de cada uno.
- Estudiar las metodologías y antecedentes de uso de la ciencia de datos en el área de la cardiología, observando qué algoritmos se han usado y qué resultados se han obtenido.
- Explorar el dataset obtenido de Kaggle, analizando cada característica, la relación entre ellas junto con la información subyacente o patrones en los datos.
- Comprobar la eficacia de las herramientas de Machine learning y Deep learning de Python, ejecutando distintos algoritmos sobre el dataset para evaluar su precisión en la clasificación y describir el marco de uso de IBM Watson Studio para aplicar algoritmos de IA sobre el dataset.
- Comparar IBM Watson con las herramientas de Python en cuanto a resultados obtenidos y evaluar el esfuerzo realizado con ambas tecnologías.
- Concluir qué herramienta es más adecuada y proponer pasos futuros dentro del ámbito de aplicación usado en éste trabajo.

4.1 Metodología

Como punto de partida, se tomarán en cuenta qué técnicas de inteligencia artificial se han usado con éxito en cardiología en estudios previos. Seguidamente se hará un estudio de los datos, y con el fin de analizar las características categóricas del dataset, se normalizarán con el codificador One Hot, usando la librería de Python Pandas.

A continuación se realizarán distintos experimentos programados en Python usando las librerías TensorFlow, Scikit-Learn y Keras. Los algoritmos utilizados se configurarán de manera que usarán un subconjunto de instancias para el entrenamiento del modelo y otro subconjunto para la prueba. En el entrenamiento se utilizará un procedimiento de optimización de hiperparámetros con el que se descubrirán los valores con los que se obtiene una mayor precisión en la clasificación. En el caso de los algoritmos de Deep Learning, el entrenamiento hará uso de Keras Tuner para la búsqueda de los hiperparámetros óptimos. Durante la ejecución de cada experimento se medirá el tiempo de ejecución de cada uno y se registrará la precisión obtenida. Tras esto, se realizarán visualizaciones relativas a la importancia de las características en cada algoritmo.

Posteriormente se realizarán otros experimentos en el framework IBM-Watson Studio, utilizando el mismo dataset, realizando las configuraciones y transformaciones necesarias para preparar los datos y aplicar los algoritmos de Machine y Deep learning de que dispongamos en la plataforma IBM. Para ello, será necesario dar de alta un usuario en IBM Cloud, con el fin de tener acceso a una cuenta de uso gratuita, crear un proyecto en el que cargar el dataset y aplicar todas las operaciones de IA. Se explicarán los módulos de IBM Watson utilizados y se mostrarán las interfaces de usuario que sean de interés para comprender los pasos realizados.

Así mismo mostrarán los resultados de precisión, velocidad y gráficas generadas, con el fin de establecer los criterios diferenciadores entre Python e IBM Watson Studio. Por último se realizará una comparativa de los experimentos de ambas plataformas, con el objetivo de identificar las bondades de ambas, así como la eficacia y efectividad de los resultados obtenidos en cada una de ellas.

Estos resultados permitirán determinar si el uso de un framework como IBM Watson Studio, puede estar a la altura de las utilizadas y citadas librerías de Python, para obtener resultados fiables sin necesidad de tener un perfil de ingeniero de datos.

5. Material y métodos

Este trabajo aborda el problema de la detección de enfermedades cardiovasculares mediante la clasificación de unos registros que contienen las mediciones de los factores de riesgo de sufrir una, y que pertenecen a pacientes de diversos hospitales. En este apartado se realizarán los siguientes pasos con el fin de resolver la cuestión planteada.

1. Marco tecnológico
   1.1. Herramientas utilizadas.
   1.2. Descripción de los algoritmos de Machine Learning usados.
   1.3. Descripción de los algoritmos de Deep Learning usados.
2. Exploración del dataset.
3. Experimentación Python Scikit-Learn, TensorFlow/Keras y con IBM Watson Studio, pruebas de precisión en la clasificación y velocidad de ejecución.
4. Referencia de otros frameworks o alternativas existentes en el mercado.

5.1. Marco tecnológico

Las tareas necesarias para la consecución del trabajo, se han realizado con un equipo portátil y software, que han sido elegidos por su adecuación a las distintas fases. A continuación se muestran las características técnicas:

1. **Marca equipo**: Apple MacBook Pro .
2. **Procesador**: Intel i7.
3. **Memoria RAM:** 16 GB.
4. **Almacenamiento**: Memoria SSD 512 GB.
5. **Sistema operativo**: MacOS Monterrey (12.0.1)
6. **Navegador WEB**: Safari (15.1).

5.1.1 Herramientas utilizadas

En los siguientes puntos se hará una breve exposición de las herramientas utilizadas para el desarrollo del trabajo, indicando las características, ventajas y adecuación.

IBM Watson Studio

Es la plataforma de software creada por IBM en 2016 para IA y ciencia de datos, inicialmente conocida como Data Science Experience, a la que se puede acceder en formato on-premise (instalado en el servidor), cloud o desktop. Aunque lleva varios años en el mercado, su uso en los últimos años se ha extendido gracias a la ampliación de sus capacidades y espacio de trabajo donde se incluyen múltiples herramientas open-source, que son susceptibles de ser utilizadas por un científico de datos para crear distintos tipos de proyectos. En la Figura 7, se observan algunas de las capacidades de Watson Studio en relación a la ciencia de datos.

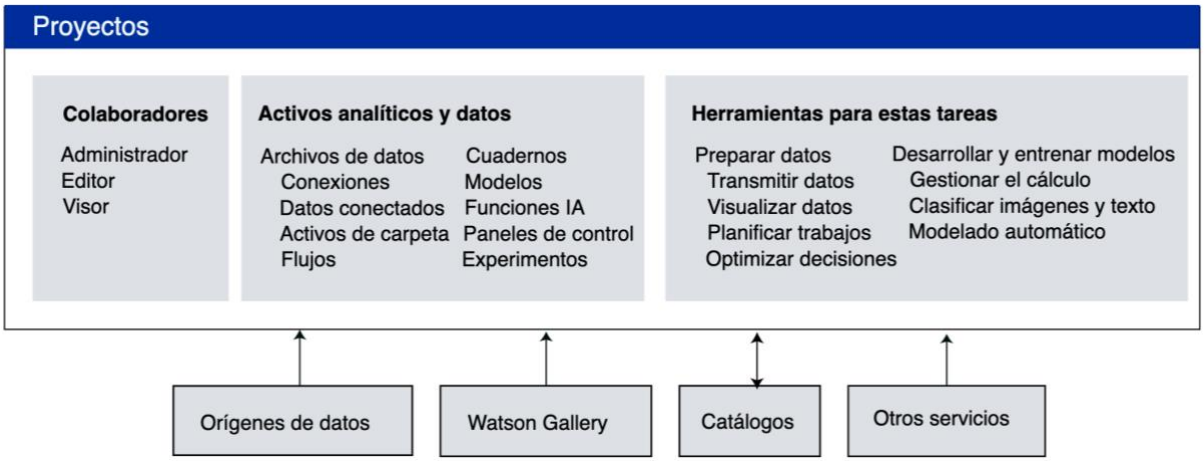

Figura 7. Capacidades de Watson Studio[13]

Algunas de sus principales ventajas son las de mejorar la experiencia de usuario, optimizar procesos y diseñar flujos de trabajo. El despliegue de sistemas con IA o Machine Learning es muy rápido y se pueden entrenar modelos de forma dinámica haciendo uso de lenguajes como R o Python. Su interfaz intuitivo permite realizar casi todas las tareas de principio a fin dentro de la ciencia de datos, desde procesos de ETL[14], análisis, generación de modelos de clasificación y predicción, hasta la generación de distintos tipos de visualizaciones para conformar cuadros de mando.

[13] Fuente: https://dataplatform.cloud.ibm.com/docs/content/wsj/landings/wsl.html
[14] Extracción, Transformación y Carga.

Microsoft Excel

La carga del dataset de Kaggle en formato CSV se hace en una hoja de cálculo de Excel, aquí se realizan consultas, aplican filtros y fórmulas sobre las variables para preparar los datos. Se utiliza la función de “Estadística descriptiva” para de obtener información sobre la distribución de los datos, como la media, desviación estándar o asimetría.

PyCharm / Jypiter Notebook

Es un entorno de desarrollo que se utiliza en programación informática, específicamente para el lenguaje Python. Permite ver las estructuras de datos en memoria durante la ejecución, la depuración de código para solucionar errores, o la ayuda a la codificación (intellisense). Se integra fácilmente con *Jupiter Notebook*, lo que permite desarrollar y visualizar prácticamente al instante, el código python desarrollado.

Python

Es un lenguaje de programación interpretado multiparadigma, dinámico y multiplataforma y el que despierta mayor interés para el desarrollo de sistemas de Machine Learning. Es fácil de aprender y usar, facilita la rápida validación de los datos y muchas librerías están orientadas a matemáticas, estadística y probabilidad, aspectos sobre los que descansa el Machine Learning, y entre las que están Pandas, Numpy, Keras, StatsModels…etc.

TensorFlow

Es un conjunto de librerías multiplataforma open-source, que proporciona API’s en Python, C++, Java, R y Scala. Su uso más frecuente es con redes neuronales para la clasificación, aunque también se utilizan para sistemas de recomendación o redes generativas adversarias. Es la herramienta más utilizada de Deep Learning junto a Keras y es útil en ámbitos como la mejora de fotografías en móviles, diagnostico médico o procesamiento de imágenes.

Keras

Es una biblioteca de redes neuronales de código abierto, escrita en Python. Está especialmente diseñada para la experimentación rápida con redes de Deep Learning. La implementación es modular y extensible y se basa en la adición de bloques secuencialmente, que constituyen una red neuronal y tiene soporte para redes neuronales convolucionales y recurrentes. El uso principal de esta biblioteca, está orientado a la inteligencia artificial en entornos industriales o de investigación. Empresas como la NASA o CERN lo usan en sus proyectos.

5.1.2 Algoritmos de Machine Learning

Tal como ha descrito en el apartado referente al uso de inteligencia artificial en la cardiología, existen algoritmos que permiten realizar operaciones sobre los datos para poder clasificar nuevas instancias o para realizar predicciones, y de los cuales conocemos a priori su clasificación (aprendizaje supervisado). A continuación se explican los más utilizados dentro de la cardiología vistos en la Tabla 2, y que serán usados en los experimentos de los capitulos posteriores.

Random Forest

En la Figura 8 se puede ver la estructura generada, su funcionamiento se basa en la clasificación de instancias en un gran número de árboles de decisión individuales, en los que cada uno contiene "n" subconjuntos aleatorios de las características totales del dataset, y que globalmente funcionan como un solo árbol.

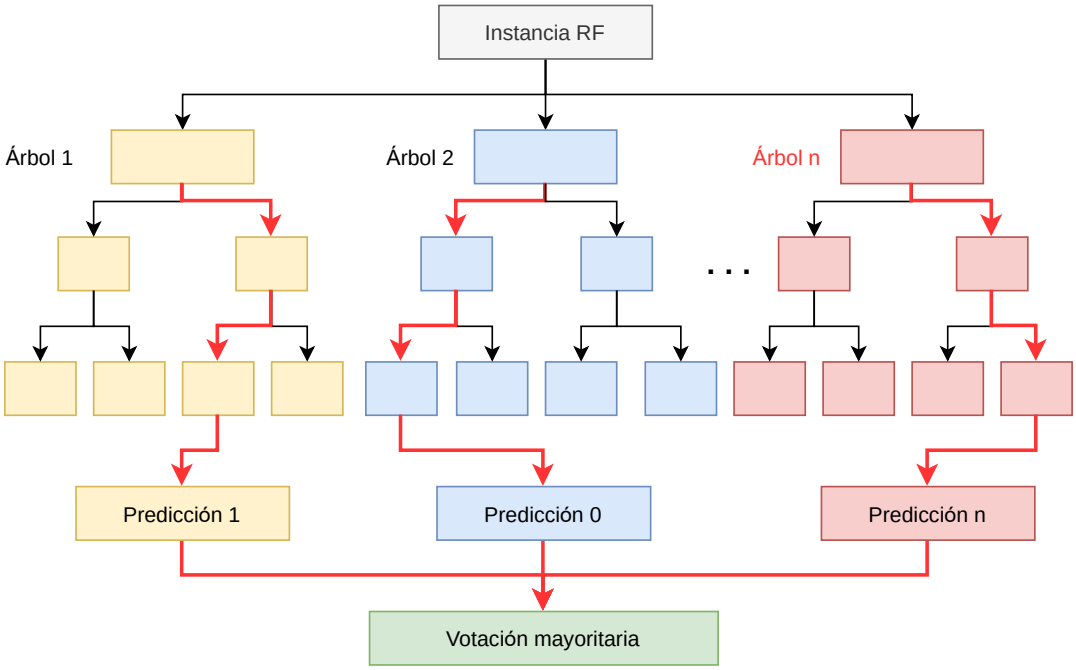

Figura 8. Clasificador Random Forest (elaboración propia)

Cada árbol obtiene una predicción de la clase objetivo y con el resultado de todos los árboles se obtiene la predicción final por mayoría, éste funcionamiento está fundamentado en el concepto de *la sabiduría de las masas*[15] denominado Ensemble Learning.

[15] https://towardsdatascience.com/understanding-random-forest-58381e0602d2

Como ejemplo de uso para la predicción de eventos cardiacos (Weng, Reps, Kai, Garibaldi, & Qureshi, 2017), RF es capaz de mejorar un 1,7% los resultados obtenidos por el algoritmo de predicción médica estándar establecido para incidentes cardiovasculares.

Support Vector Machines

Se trata de un algoritmo usado comúnmente en problemas de clasificación y tiene como principales ventajas, el bajo coste computacional en relación a la precisión obtenida y la poca sensibilidad ante valores atípicos. El objetivo de este algoritmo es la búsqueda de un hiperplano en un espacio N-dimensional[16] (N es el numero de características), que clasifique de manera diferenciada los datos. Los vectores de soporte son los puntos más cercanos al hiperplano y determinan el margen del clasificador el cual se quiere maximizar. La eficacia de SVM se ha probado para predecir arritmias cardiacas (Ebrahimzadeh, y otros, 2018), sobre determinados conjuntos de datos, llegando a obtener una precisión del 93%, por encima incluso de otros como el K-Nearest Neighbors con el 85%.

Gradient boosting

Es una técnica de Machine Learning usada para el análisis de regresión y para problemas de clasificación[17]. Su modelo predictivo, tal como se observa en la Figura 9, se estructura en forma de árboles de decisión escalonados, el entrenamiento procesa muchos árboles y modifica los pesos en cada paso para corregir los errores de los modelos anteriores. Utiliza una función de pérdida, que es una medida que indica cuán bueno es el coeficiente del modelo que está ajustando los datos. Las ventajas de GB son la velocidad y la exactitud, sobre todo cuando se usan gran cantidad de datos complejos.

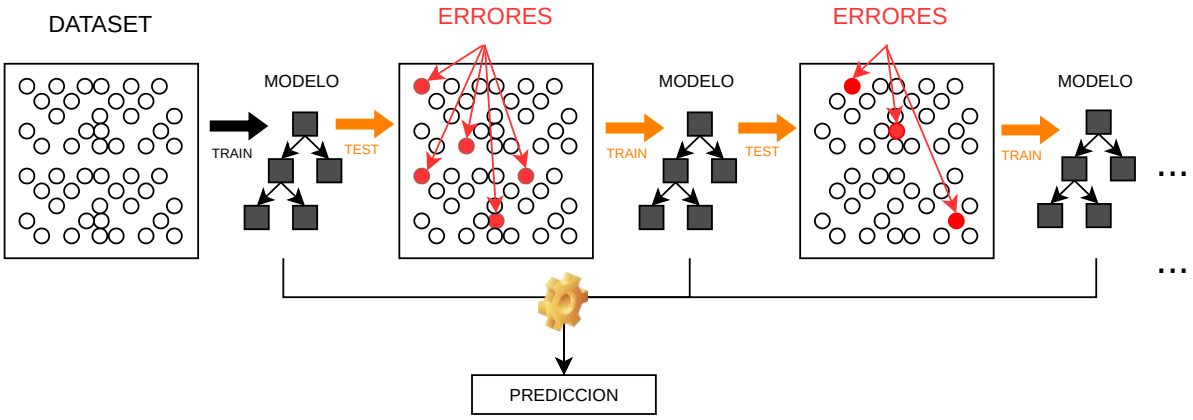

Figura 9. Clasificador Gradient Boosting (elaboración propia)

[16] https://towardsdatascience.com/https-medium-com-pupalerushikesh-svm-f4b42800e989
[17] https://docs.paperspace.com/machine-learning/wiki/gradient-boosting

5.1.3 Algoritmos de Deep Learning

Dentro de la inteligencia artificial, son aquellos que están relacionados con las redes neuronales artificiales (RN / RNA), que son estructuras procesamiento no lineales capaces de realizar transformaciones de los datos entre diferentes capas. El objetivo de las RN es buscar modelos que solucionen problemas para extraer información útil e inferir clases a partir de datos de entrada y a través del aprendizaje. Las RN suelen usarse para problemas de análisis de regresión y clasificación binaria como es el caso de uso de éste trabajo.

Perceptrón Multicapa (MLP)

Se trata de un tipo de red neuronal compuesto por un conjunto de unidades llamadas neuronas, conectadas entre sí y organizadas en capas entre las cuales se transmite información. La estructura tiene una ***capa de entrada*** con una neurona por variable de entrada, y una o varias ***capas ocultas*** con “n” neuronas cada una, a las que se transmite la información y donde se realizan transformaciones en base a una función de activación y unos pesos que se van recalculando, para finalmente desembocar en la ***capa de salida*** que calcula el resultado.

El uso del perceptron multicapa (Multilayer Perceptron - MLP) en cardiología ha tenido éxito como en el diagnóstico de pacientes con insuficiencia cardiaca (Medved, y otros, 2018), con mejores resultados y precisión que el modelo tradicional de valoración de riesgo (IMPACT).

5.2. El dataset

El dataset objeto de este trabajo está contenido en un fichero denominado "`heart.csv`", con formato de texto plano separado por comas, el cual contiene en la primera línea el nombre de cada característica, y en el resto de líneas las distintas instancias relativas a diferentes pacientes, tal como se puede observar en la Figura 10 del siguiente extracto del fichero.

```
Age,Sex,ChestPainType,RestingBP,Cholesterol,FastingBS,RestingECG,MaxHR,ExerciseAngina,Oldpeak,ST_Slope,heartDisease
40, M, ATA, 140, 289, 0, Normal, 172, N,  0, Up  , 0
49, F, NAP, 160, 180, 0, Normal, 156, N,  1, Flat, 1
37, M, ATA, 130, 283, 0,     ST,  98, N,  0, Up  , 0
60, M, ASY, 142, 216, 0, Normal, 110, Y,2.5, Flat, 1
67, M, ASY, 120,   0, 1, Normal, 150, N,1.5, Down, 1
…
```

Figura 10. Extracto del fichero heart.csv

El dataset está integrado por datos de pacientes pertenecientes a distintos hospitales[18] que han sido combinados para formar un conjunto de 918 instancias y 12 atributos. Éstos indicadores, en función de los valores que toman, determinan si se padeció o no una enfermedad cardiovascular[19]. Las diferentes combinaciones de esos valores sirven para, a través de los algoritmos de IA, encontrar patrones que permitan realizar una predicción / clasificación de nuevos pacientes infiriendo su variable objetivo. En los siguientes apartados, se realizará una introducción a los datos que se usarán para el estudio, exponiendo primeramente, trabajos previos sobre los mismos.

5.2.2 Antecedentes de uso.

El dataset ha sido objeto de estudio en Kaggle por diferentes usuarios, que han probado distintos algoritmos de clasificación prestando atención a la precisión. El código que más votaciones ha recibido en ésta plataforma es el de Kaan Boke[20], un experimentado investigador de ciencia de datos Finlandés. Su código desarrollado en Python, muestra diversos datos estadísticos y pruebas con diferentes algoritmos de aprendizaje supervisado, y obtiene una excelente precisión del 90,4% utilizando Catboost[21] con optimización de hiperparámetros mediante el framework Optuna.

[18] Cleveland, Hungría, Suiza, Long Beach, Starlog dataset. https://archive.ics.uci.edu/ml/machine-learning-databases/heart-disease/

[19] Los valores de cada variable independiente del dataset, determinan para cada instancia/paciente, si se padeció o no una enfermedad cardiovascular (sin especificar cuál en concreto) y que se indica en la variable "`heartDisease`" del dataset.

[20] https://www.kaggle.com/kaanboke

[21] Librería opensource https://catboost.ai

El objetivo de este trabajo es, además, usar los algoritmos más comúnmente utilizados en cardiología para clasificar las instancias, utilizar la optimización de hiperparámetros en aquellos donde Kaan Boke no ha usado, e incorporar técnicas de Deep Learning como otra opción muy válida para intentar mejorar la mejor precisión obtenida.

5.2.3 Exploración de las variables.

El dataset consta de 12 columnas, cada registro contiene, valores clínicos de los factores de riesgo medidos a un determinado paciente (variables predictoras) y el desenlace ocasionado en base a los mismos (variable predicha).

1. **Age**: Esta variable cuantitativa discreta representa la edad del paciente, los valores están comprendidos entre 28 y 77 años. En la Figura 11 se observa que la mayor parte de los pacientes con ECV se concentran en el rango de edad de entre 49 y 64 años.

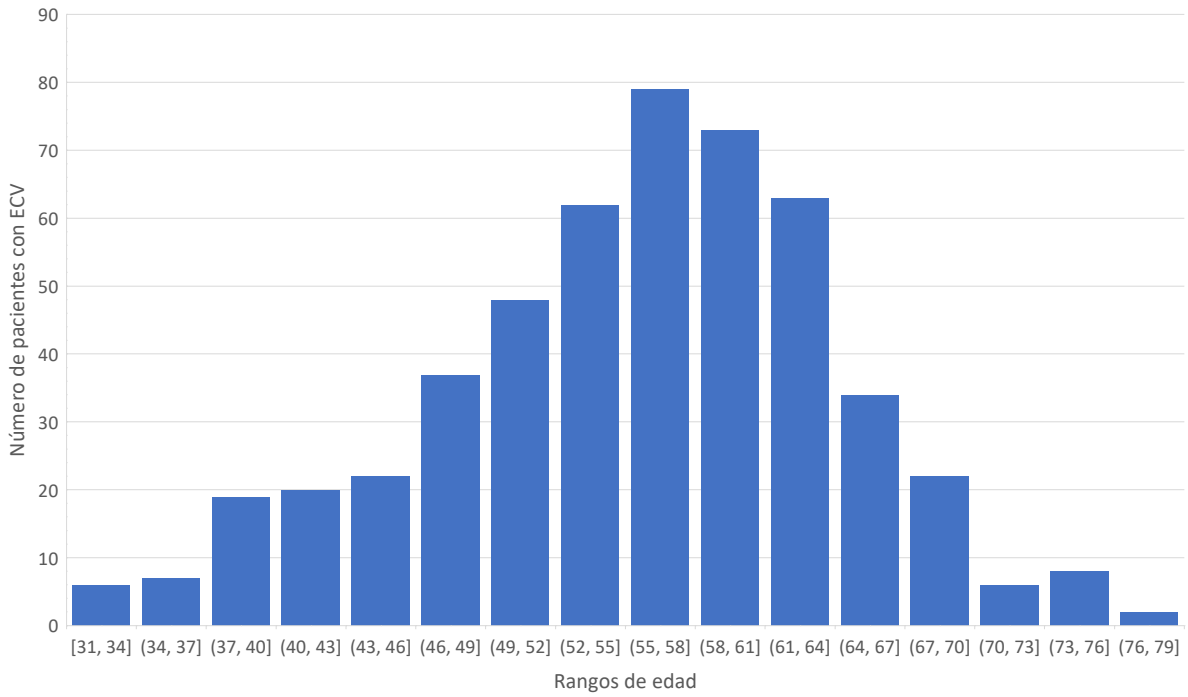

Figura 11. Distribución de pacientes con ECV en función de la edad.

Descripción de los datos: De los datos de la siguiente Tabla 3 se observa que la distribución es ligeramente platicúrtica, tiene una asimetría negativa es decir hay más pacientes cuya edad están por encima de la media que por debajo.

Tabla 3. Análisis de los datos de edad.

Age	
Media	53,51089325
Error típico	0,311322735
Mediana	54
Moda	54
Desviación estándar	9,432616507
Varianza de la muestra	88,97425416
Coeficiente de asimetría	-0,195933029
Rango	49
Mínimo	28
Máximo	77
Nivel de confianza (95,0%)	+/-0,610987784

2. **Sex:** La variable categórica, representa el género o sexo del paciente, los posibles valores son "M" para hombre (Male) y "F" para mujer (Female). Tal como se muestra en la Figura 12, la proporción de personas enfermedad cardiovascular (ECV) representa el 62% del total de hombres y el 26% del total de mujeres.

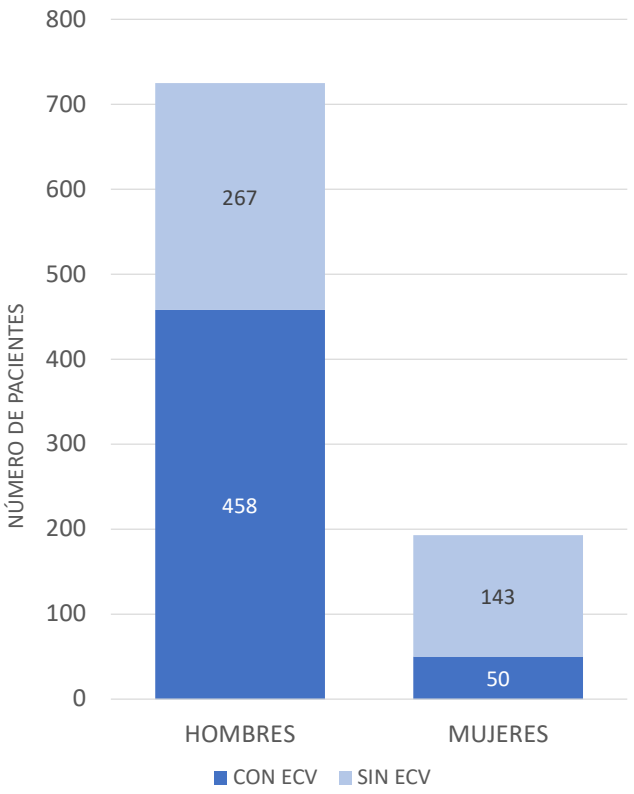

Figura 12. Proporción sanos y con ECV por sexo.

3. **<u>ChestPainType</u>:** Se trata de una variable nominal que indica el tipo de dolor pectoral, los posibles valores son "TA" para angina típica, "ATA" para angina atípica, "NAP" otro dolor, y "ASY" para asintomático. En el conjunto de datos, la distribución de los valores para esta variable, es la que se observa en la Figura 13.

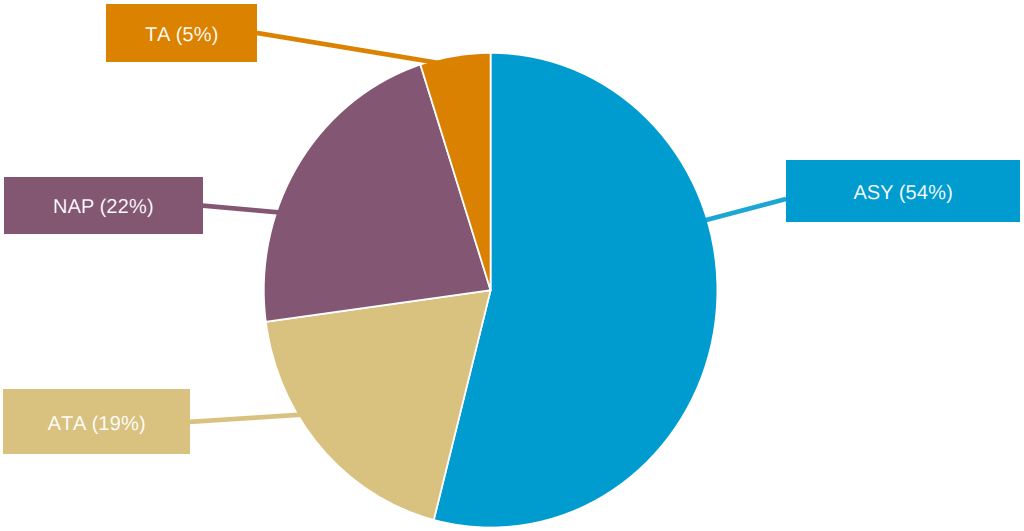

Figura 13. Distribución de valores de tipo de dolor de pecho

4. **<u>RestingBP</u>:** Almacena valores cuantitativos discretos, se trata de la presión sanguínea en reposo, y se mide de forma manométrica en milímetros de mercurio (mm/Hg). Sus valores en el dataset van desde 0 mm/Hg hasta 200 mm/Hg. Tal como se muestra en la Figura 14, el rango de valores más común entre los pacientes está entre 125 y 140.

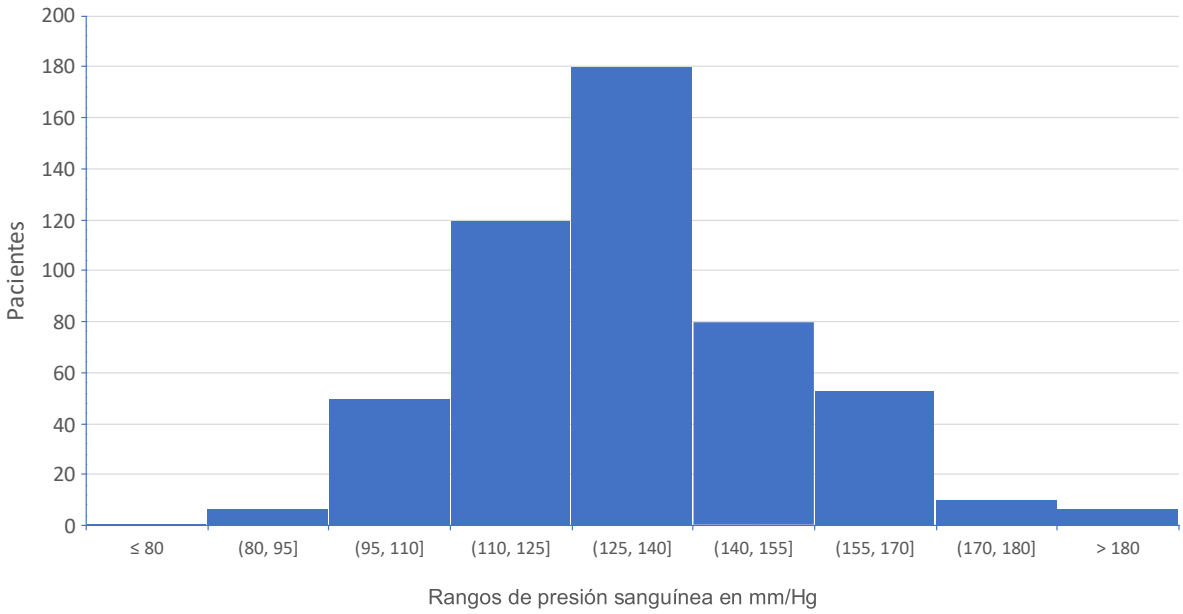

Figura 14. Distribución de la presión sanguínea de todos los pacientes

Descripción de los datos: En la Tabla 4 se observa, que ésta variable tiene una distribución leptocúrtica, además de una asimetría positiva es decir hay más pacientes cuyo rango de presión sanguíneo están por debajo de la media que por encima. Se puede decir que la desviación estándar es baja, ya que la mayor parte de los valores se concentran cerca de la media.

Tabla 4. Análisis de los datos de presión sanguínea en reposo.

RestingBP	
Media	132,3965142
Error típico	0,61105814
Mediana	130
Moda	120
Desviación estándar	18,51415412
Varianza de la muestra	342,7739028
Coeficiente de asimetría	0,17983931
Rango	200
Mínimo	0
Máximo	200
Nivel de confianza(95,0%)	1,199234803

5. **Cholesterol:** Es una variable cuantitativa discreta que mide el colesterol en sangre en miligramos por decilitro, los valores van desde 100 hasta 603. Como se muestra en la Figura 15, los niveles de colesterol más representativos están en el rango de 220 a 280 mg/dl. Se quitaron los valores igual 0 por significar ausencia de medición y 603 por ser incoherente.

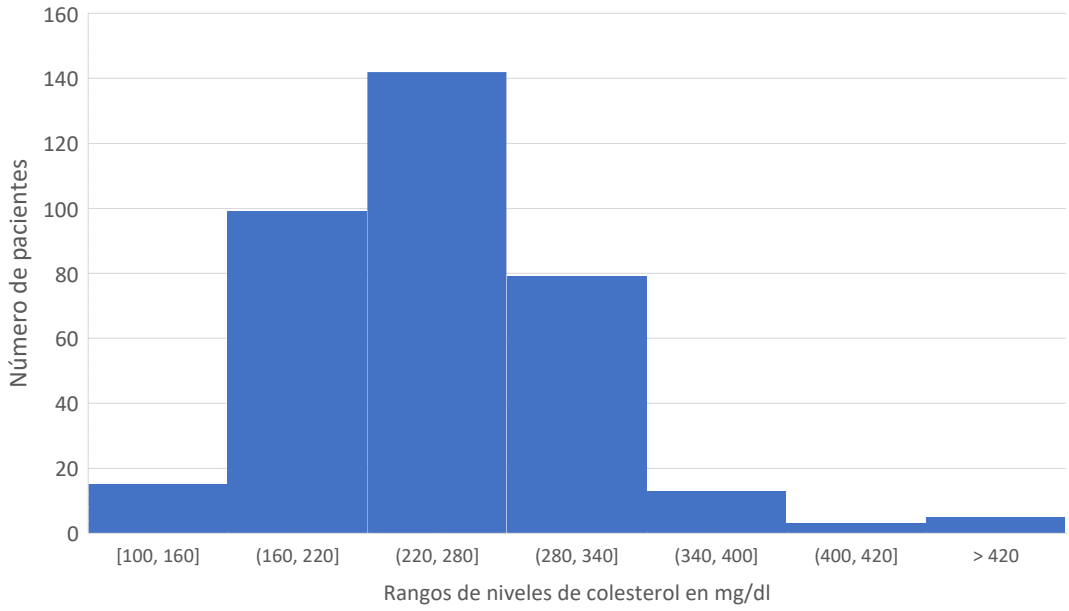

Figura 15. Distribución de niveles de colesterol entre los pacientes con ECV.

Descripción de los datos: Como se muestra en el análisis descriptivo de la Tabla 5, que la distribución es ligeramente leptocúrtica, con una asimetría positiva es decir hay más pacientes cuyo rango de colesterol está más por debajo de la media que por encima. Se puede decir que la desviación estándar es baja, ya que la mayor parte de los valores se concentran cerca de la media.

Tabla 5. Análisis de los datos de colesterol.

Cholesterol	
Media	244,1543624
Error típico	2,114506083
Mediana	237
Moda	254
Desviación estándar	57,71478408
Varianza de la muestra	3330,996302
Coeficiente de asimetría	1,037722555
Rango	479
Mínimo	85
Máximo	564
Nivel de confianza(95,0%)	4,151108743

6. **FastingBS:** Indica el nivel de azúcar en sangre en ayunas medido en miligramos por decilitro, se encuentra codificado según sea peligroso o no, siendo "1" peligroso cuando supera 120 mg/dl y "0" si es inferior a esa cifra. Como se ve en la Figura 16, el porcentaje de entre los hombres (33%) y de entre las mujeres (32%) con azúcar alto, es similar.

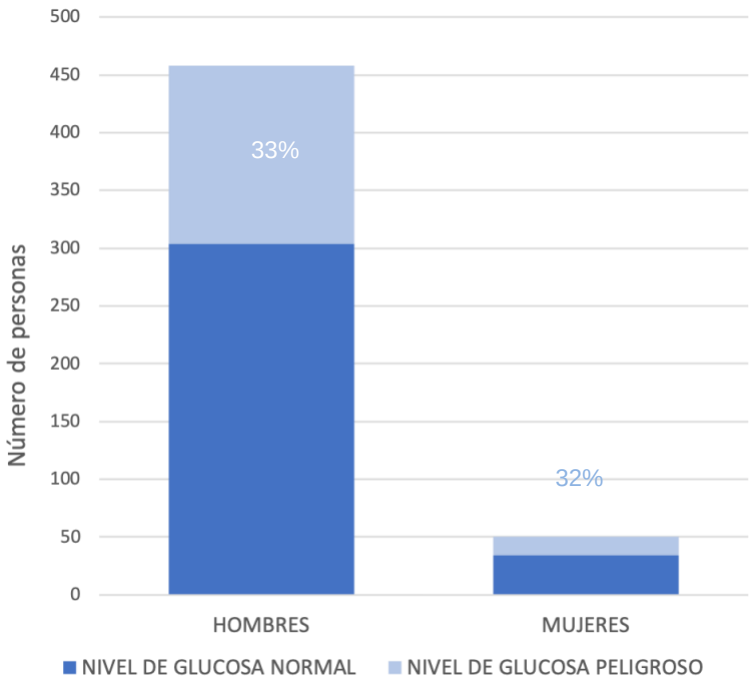

Figura 16. Distribución por sexo niveles de glucosa en enfermos de ECV.

7. **RestingECG:** Variable categórica que indica el valor en una ECG, los valores son "Normal" si no se observa anomalía, "ST" si se observó una anomalía en el segmento ST, tanto por elevación de como por depresión respecto de los valores típicos, y "LVH" que muestra la presencia de hipertrofia en el ventrículo izquierdo. En la siguiente figura se observa que la distribución de pacientes con alguna anomalía cardiaca, es del 48% respecto al 52% que presentan patrones normales.

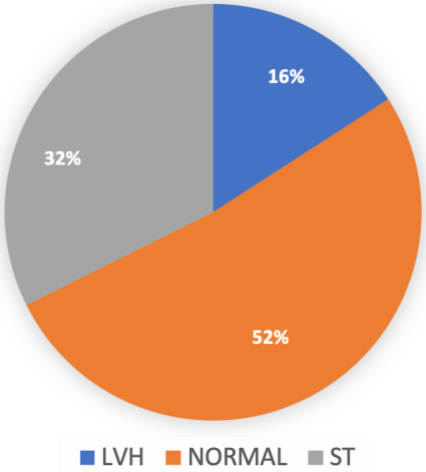

Figura 17. Distribución de anomalías en la electrocardiografía, para pacientes con ECV.

8. **MaxHR**: Representa los máximos latidos alcanzados por el paciente, sus valores están entre 60 y 202**.** En la Figura 18, se aprecia que los rangos de 110 a 130 pulsaciones máximas son los más representativos de la distribución entre pacientes con ECV.

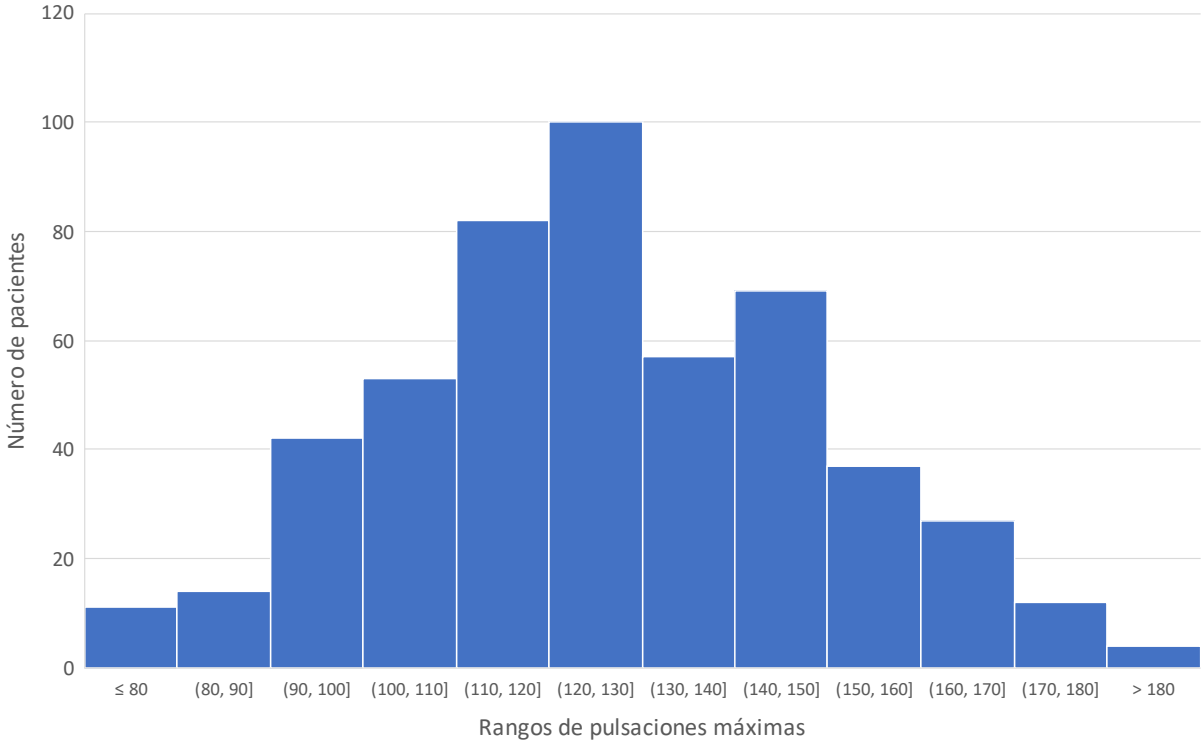

Figura 18. Rangos de pulsaciones máximas por número de pacientes con ECV.

Descripción de los datos: De la Tabla 6 se deduce, que la distribución es ligeramente leptocúrtica, con asimetría positiva. Hay más pacientes cuyo rango de colesterol está por debajo de la media que por encima. Se puede decir que la desviación estándar es baja, ya que la mayor parte de los valores se concentran cerca de la media.

Tabla 6. Análisis valores de pulsaciones máximas

MaxHR	
Media	136,8093682
Error típico	0,840316243
Mediana	138
Moda	150
Desviación estándar	25,46033414
Varianza de la muestra	648,2286144
Curtosis	-0,44824782
Coeficiente de asimetría	-0,144359418
Rango	142
Mínimo	60
Máximo	202
Nivel de confianza(95,0%)	1,649166286

9. **ExerciseAngina:** La variable categórica indica si previo al dolor de angina, se realizó ejercicio físico o no. Sus valores son "Y" para si y "N" para no. En la Figura 19 se muestra la proporción por sexo de personas con ECV en las que el ejercicio indujo o no a la angina de pecho.

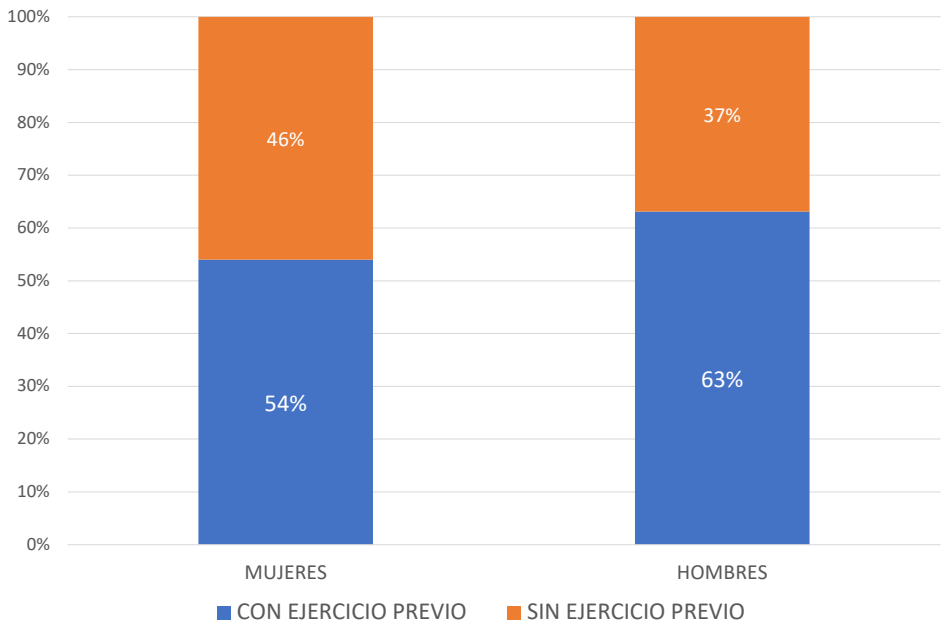

Figura 19. Proporción de personas con ECV con dolor de angina por ejercicio previo.

10. **OldPeak:** La variable numérica representa en una electrocardiografía el valor asociado al segmento ST[22], inducido por un ejercicio previo y estando de reposo. Será ascendente (positivo), plano (0) o descendente (negativo) y está relacionado con la variable "Slope". Sus valores van desde -2 mm hasta 6 mm. En la Figura 20, se ve el intervalo más representativo entre 0,5 y 1,5 mm de los pacientes con ECV.

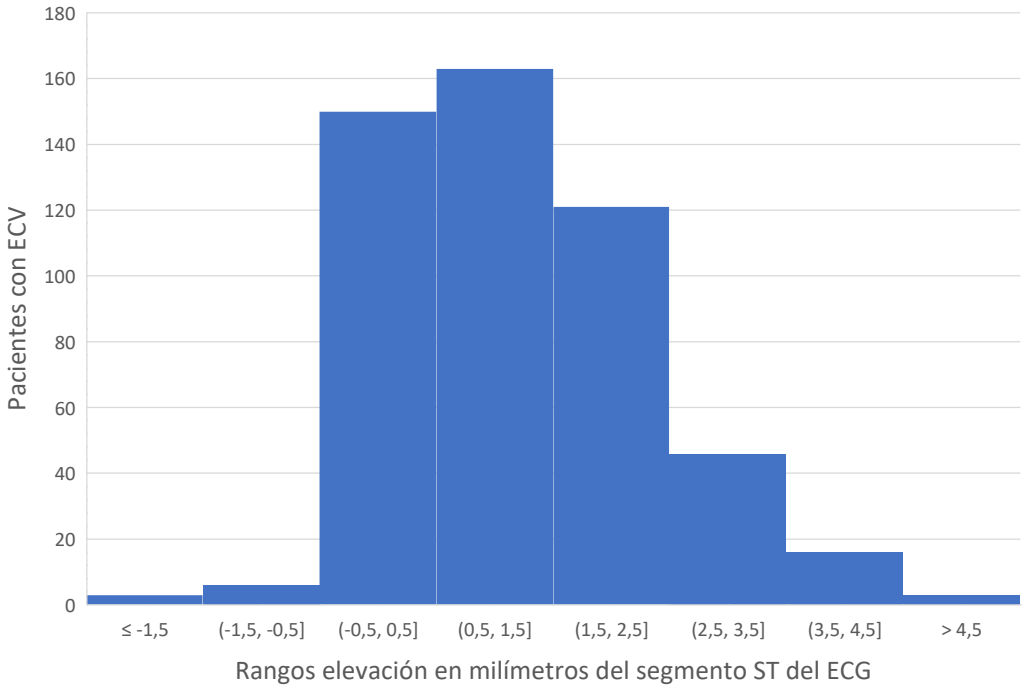

Figura 20. Distribución de elevación segmento ST en pacientes con enfermedad cardiaca.

Descripción de los datos: Tal como se deduce de la Tabla 7, la distribución es leptocúrtica, con asimetría positiva, hay más pacientes cuya elevación ST está por debajo de la media que por encima.

Tabla 7. Análisis de los valores de OldPeak

OldPeak	
Media	0,887363834
Error típico	0,03520206
Mediana	0,6
Moda	0
Desviación estándar	1,066570151
Varianza de la muestra	1,137571887
Curtosis	1,203063684
Coeficiente de asimetría	1,022872022
Rango	8,8
Mínimo	-2,6
Máximo	6,2
Nivel de confianza(95,0%)	0,069085956

[22] https://litfl.com/st-segment-ecg-library/

11. **ST_Slope:** La variable categórica indica la pendiente del segmento ST medido en la electrocardiografía, está relacionada con la variable anterior (`Oldpeak`). Si el segmento presenta un aspecto ascendente contendrá "Up", descendente "Down" y plano "Flat". El criterio médico para estimar la normalidad de los pares "Slope-Oldpeak", dice que una pendiente plana o descendiente >1 mm no es normal y por tanto presenta una cardiopatía, (Lim, Teo, & Poh, 2016). En la Figura 21 se muestra la distribución de estos 3 tipos entre los pacientes con ECV.

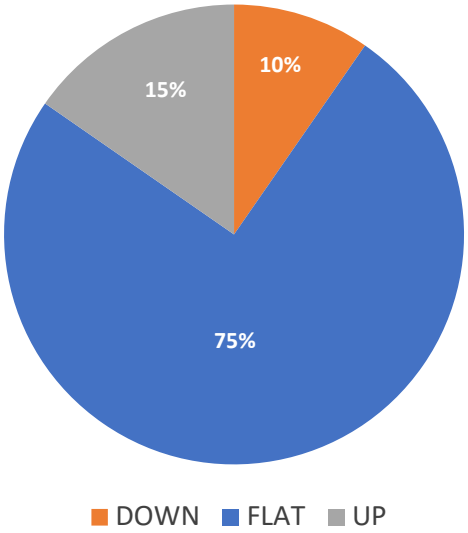

Figura 21. Distribución de la forma Segmento ST en personas con ECV.

La *variable dependiente o predicha*, contiene el desenlace de padecer o no una enfermedad cardiovascular (ECV), en base a las características descritas arriba.

12. **HeartDisease:** Se trata de una variable discreta, dependiente del resultado de la clasificación o predicción, contiene los valores codificados de "1" si el paciente sufre enfermedad cardiovascular o "0" si no la sufre. En la siguiente figura se observa la proporción de pacientes en relación a los valores de esta variable.

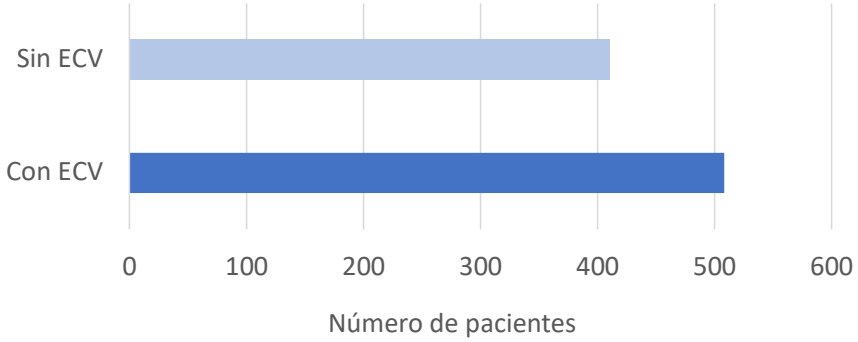

Figura 22. Proporción de pacientes con y sin ECV.

5.2.3 Correlación entre las variables.

El gráfico de correlación muestra la asociación entre las variables numéricas del dataset. Se aprecia que no existe acoplamiento alto entre ningún par de variables, la graduación divergente de la Figura 23, roja y azul nos indica la fuerza de la relación, la mayor es la pareja de variables independientes ***ST_depresion - Enfermedad_cardiaca*** con un valor de 0.40.

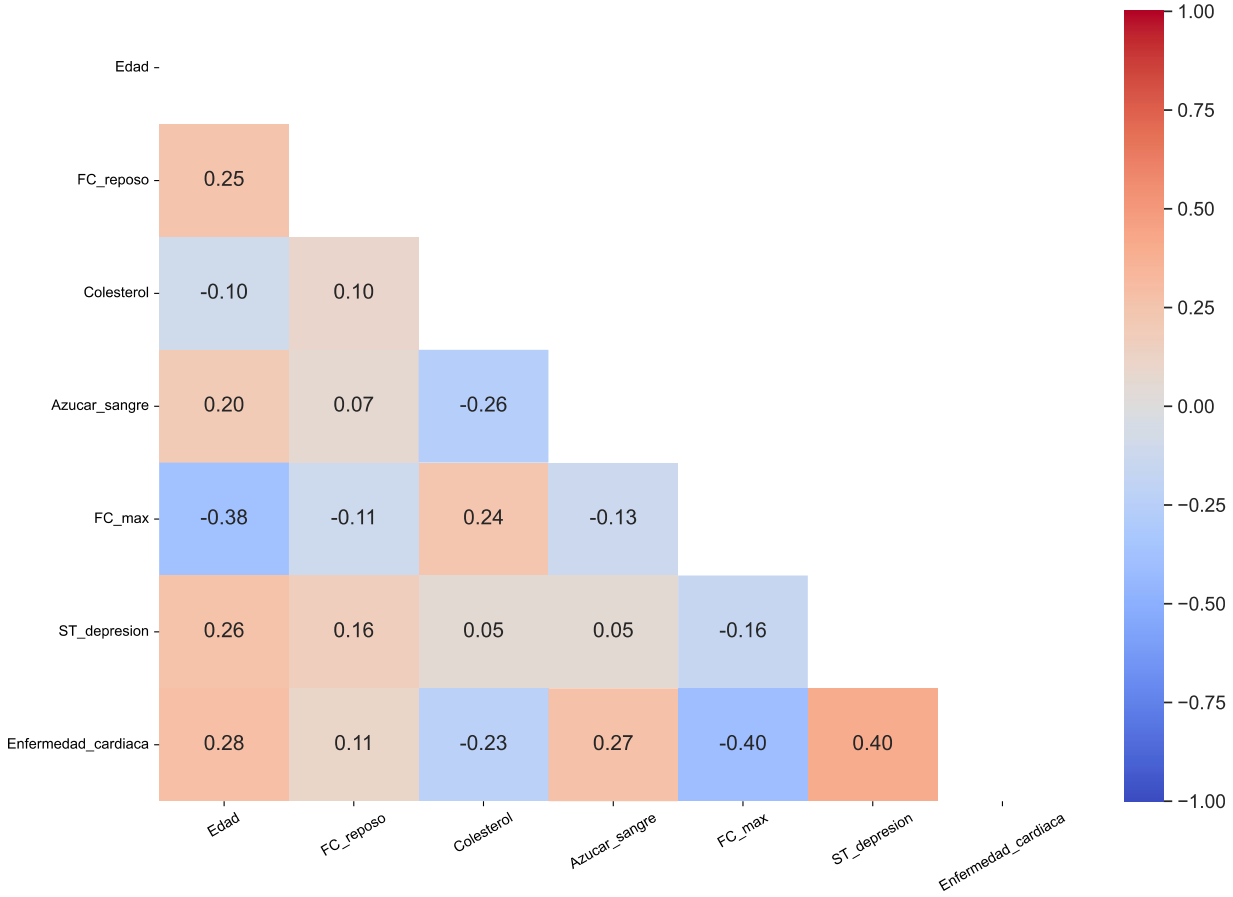

Figura 23. Correlación entre las variables independientes.

5.2.4 Protección de datos RGPD

La utilización del dataset obtenido de la plataforma Kaggle[23], está sujeta a las licencias "Open Data Commons[24]" y "Open Database License" las cuales permiten a los usuarios compartir, modificar y usar los mismos libremente. Los datos médicos están especialmente protegidos al ser de carácter personal por el RGPD y la LOPD, y éstos han sido convenientemente anonimizados antes de ser publicados en la citada plataforma, de forma que no es posible relacionar ningún aspecto médico con ninguna persona física. La única identidad que conservan los datos, son el origen de los centros médicos de los cuales se extrajeron.

[23] https://www.kaggle.com/fedesoriano/heart-failure-prediction?select=heart.csv#:~:text=calendar_view_week-,heart,-.csv
[24] https://opendatacommons.org/licenses/odbl/1-0/

5.3. Detección de ECV con Machine Learning

En este capítulo se tratará de demostrar qué técnicas de las más utilizadas en el ámbito cardiológico, consiguen clasificar con mayor precisión el padecimiento o no de una enfermedad cardiovascular en base a los registros de entrenamiento del dataset. Para los experimentos se usarán algoritmos de aprendizaje supervisado con los que se medirá la precisión y el tiempo de ejecución de cada uno. Así mismo se utilizará el framework Optuna para demostrar si se pueden mejorar los resultados obtenidos de cada algoritmo optimizando sus hiperparámetros. Finalmente se compararán los resultados obtenidos de todos ellos.

5.3.1 Preparación del dataset

Inicialmente se preparan los datos cargándolos del fichero `heart.csv` en una estructura similar a una tabla denominada *dataframe*. Para ello se ha utilizando la librería Python *Pandas* y la función de utilidad `read_csv()`.

Ingeniería de características

Para de mejorar la efectividad de los algoritmos de clasificación, se transforman en numéricas las características categóricas `Sex`, `ChestPainType`, `RestingECG`, `ExerciseAngina` y `ST_Slope`, y se usa el codificador *One Hot Encoder* de la librería `Pandas`. Con la función `get_dummies()` se extraen los valores de éstas columnas y se crean tantas otras de más, como valores tenga cada característica, estableciendo el valor 1 o 0 para marcar la que aplica en cada caso, tal como se ve en la Figura 24.

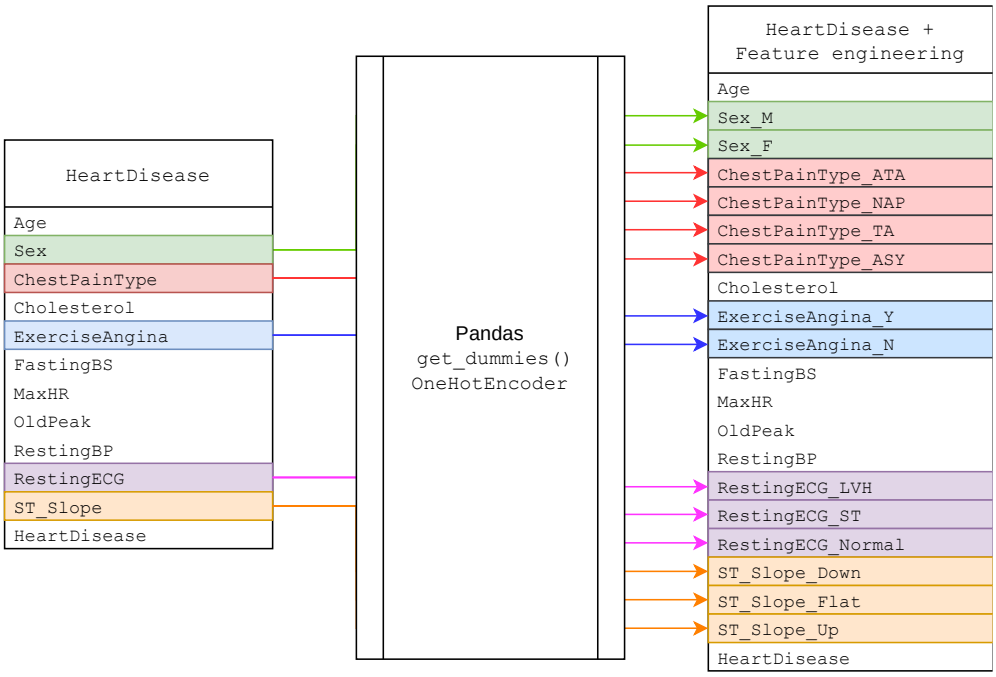

Figura 24. Resultado de aplicar ingeniería de variables

Tras realizar la normalización se realiza la división del dataframe en dos. Un dataframe con las columnas de variables dependientes denominado `featuresData`, y otro con la columna que contiene los valores de la clase objetivo llamado `resultData`. Previamente obtiene un conjunto de instancias de entrenamiento y otro de prueba, y se particionan los dataframes `features` y `result`, de forma que el 70% instancias son para el entrenamiento y el 30% instancias para prueba, resultando 4 dataframes (`feat_train, feat_test, result_train, result_test`).

5.3.2 Primer experimento: Random Forest

En este experimento se va a comprobar la capacidad de clasificación de las instancias del dataset a través de un algoritmo basado en árboles. Con la clase `RandomForestClassifier` entrenamos el modelo utilizando los datos de `feat_train`, y se predice con el dataframe de características de test, `feat_test`. Con los valores por defecto la precisión obtenida es 88,76%, el algoritmo tarda 0,69 segundos. Posteriormente y usando Optuna, se aplican al algoritmo los hiperparámetros optimizados y se obtiene un 90,57% en la precisión, tal y como se aprecia en la Tabla 8 y en la salida de consola mostrada a continuación, en ambos casos, se consigue mejorar levemente la precisión obtenida Kaggle con Random Forest.

```
[I 2021-12-11 19:23:21,288] Trial 11 finished with value: 0.9057971014492754 and parameters: {'rf_n_estimators': 87, 'rf_max_depth': 11, 'rf_min_samples_split': 9, 'rf_min_samples_leaf': 2}. Best is trial 11 with value: 0.9057971014492754.
```

Tabla 8. Valores obtenidos de precisión de Random forest sin y con optimización de Optuna

Parámetro	Descripción	Valores por defecto	Hiperparámetros optimizados con Optuna[25]
min_samples_leaf	El número mínimo de muestras necesarias para ser un nodo hoja	1	2
min_samples_split	El número mínimo de **muestras** necesarias para dividir un nodo	2	9
max_depth	Profundidad máxima del árbol	None (Dynamic)	11
n_estimators	Número de árboles en el bosque	100	87
Precisión		88,76%	90,57%
Tiempo ejecución		0,69 s.	0,72 s.

[25] Mejora con ingeniería de variables algo más de un 1% la precisión del código más votado en Kaggle, y mejora un 2% con la optimización de los hiperparámetros. https://www.kaggle.com/kaanboke/beginner-friendly-catboost-with-optuna/notebook

Importancia de las características

Dado el conjunto de características con el que se entrenó este algoritmo de cara a la clasificación las variables, se pueden obtener las variables con más importancia en el modelo Random Forest. Destacan las relacionadas con la elevación del segmento ST en la electrocardiografía y también la variable `OldPeak`, que ocupa la 3ª posición, tal como se muestra en la Figura 25.

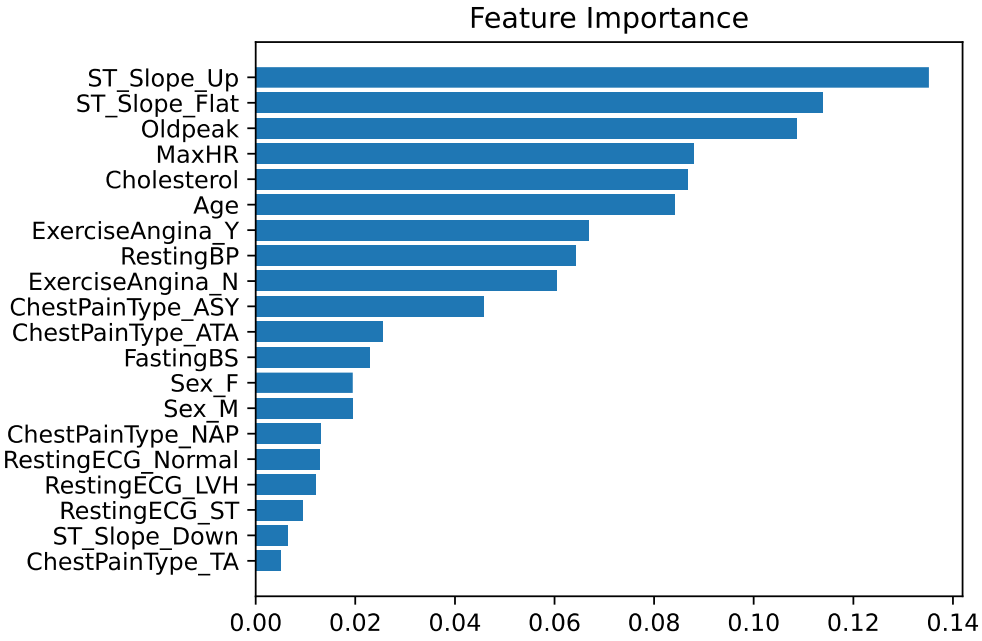

Figura 25. Random forest importancia de las variables clasificadoras

Matriz de confusión

La Figura 26 corresponde a la matriz que genera el algoritmo con los parámetros optimizados. Se observa que la clasificación que ha realizado el algoritmo, ha sido más precisa para las instancias en las que la clase es 1, (tiene una ECV) .

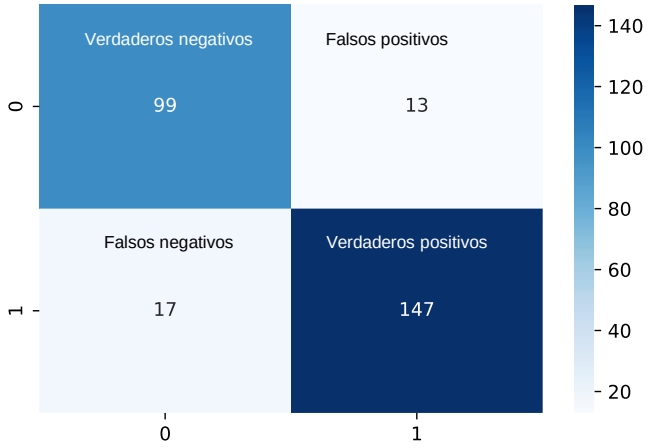

Figura 26. Matriz de confusión Random Forest

5.3.3 Segundo experimento: Gradient Boosting

En este experimento se utiliza también la librería de `sklearn.ensemble`, para hacer uso del clasificador de la clase `GradientBoostingClassifier.` Al ejecutar el algoritmo con los parámetros por defecto, se obtiene una precisión de 87,68% y un tiempo de ejecución de 0,49 segundos.

Para intentar mejorar estos resultados, se optimizaron los hiperparámetros con el framework Optuna, para lo cual es necesaria la definición de unos rangos de valores para los parámetros más críticos implicados en la precisión, así como definir una función que iterativamente irá probándolos, tal como se muestra en el código a continuación.

```
import optuna
from sklearn.ensemble import GradientBoostingClassifier
from optuna.samplers import RandomSampler
from sklearn.metrics import accuracy_score

def objective(trial):

  # Definición de los rangos de prueba para cada hiperparámetro
  vsubsample = trial.suggest_float('subsample', 0.1, 1.0)
  vlearningrate = trial.suggest_float('learning_rate', 0.01, 0.2)
  vestimators = trial.suggest_int('n_estimators', 50, 130)

  clf = GradientBoostingClassifier ( subsample = vsubsample,
                                     learning_rate = vlearningrate,
                                     n_estimators = vestimators,
                                     random_state = 0 )
  # Entrenamiento del modelo
  clf.fit(features_train, result_train)

  # Predicción con datos de prueba
  prediction = clf.predict(features_test)

  # Cálculo de la precisión con resultados de prueba
  accuracy = accuracy_score(result_test['HeartDisease'].to_numpy(), prediction)

  return accuracy

study = optuna.create_study(sampler=RandomSampler(),direction='maximize')
study.optimize(objective, n_trials=100)
```

Al ejecutar la búsqueda de hiperparámetros, tras 76 segundos y 100 iteraciones, se obtiene una precisión en la clasificación de 89,85%. Los valores de los parámetros encontrados se muestran en la Tabla 9. La salida de la ejecución del algoritmo con Optuna (mostrado a continuación), informa de la mejor precisión obtenida, los parámetros que fueron optimizados y la iteración o intento en el que se produjo (Trial).

```
[I 2021-12-09 15:19:21,337] Trial 40 finished with value: 0.8985507246376812 and parameters:
{'subsample': 0.2648216762126892, 'learning_rate': 0.07402688398135922, 'n_estimators': 62}.
Best is trial 40 with value: 0.8985507246376812.
```

Tabla 9. Precisión de Gradient boosting con y sin optimización de hiperparámetros con Optuna.

Parámetro	Descripción	Valores por defecto	Hiperparámetros optimizados con Optuna[26]
`subsample`	Proporción de muestras usadas para el ajuste del aprendizaje	1,0	0,2648216762126892
`learning_rate`	Capacidad para corregir el error entre los árboles	0,1	0,07402688398135922
`n_estimators`	Número de árboles en el bosque	100	62
Precisión		87,68%	89,85%
Tiempo ejecución		0,52 s.	0,27 s.

Importancia de las características

En la Figura 27 se observa la distribución del impacto de cada característica en el modelo y la influencia de sus valores. Tal como se aprecia, el valor "1" en la característica `ST_Slope_Up` y los valores altos de la característica `Oldpeak` tienen una importante influencia sobre el padecimiento de una enfermedad cardiovascular.

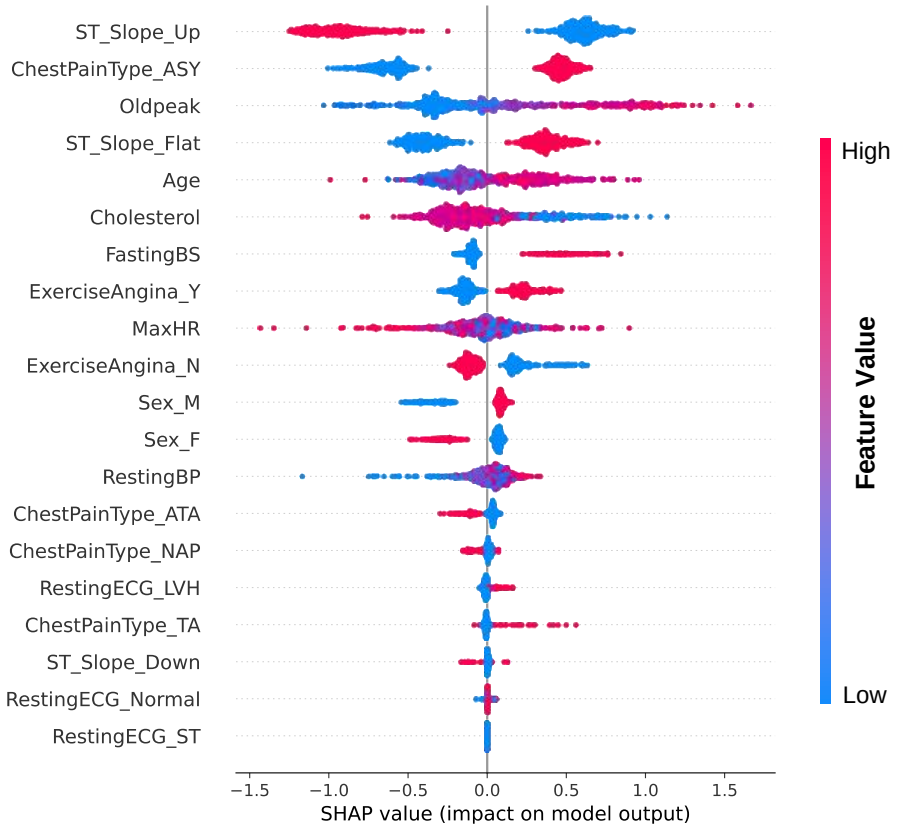

Figura 27. Gradient Boosting importancia de las variables clasificadoras

[26] Mejora un 2% la precisión del aporte más votado en Kaggle con éste algoritmo y sobre éste dataset.

Matriz de confusión

La siguiente figura nos muestra cómo el algoritmo consigue clasificar mejor las instancias en las que la clase `HeartDisease` es igual a 1, es decir, aquellas que detectan la enfermedad cardiovascular.

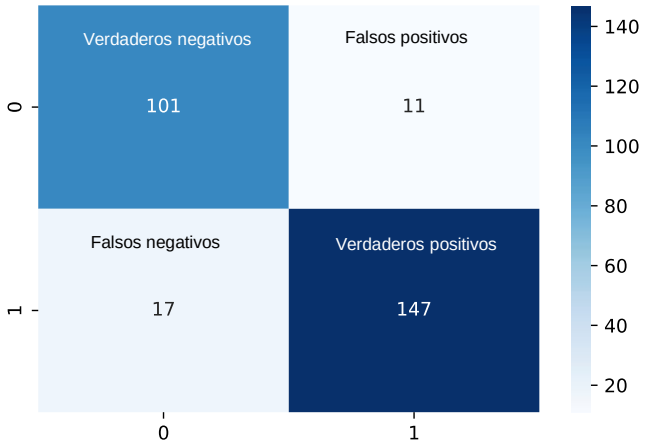

Figura 28. Matriz de confusión Gradient Boosting

5.3.2 Tercer experimento: Supported Vector Machines

En este experimento se utiliza la librería `Sklearn` para ejecutar el algoritmo SVM. El uso de Optuna con SVM, demuestra que es una herramienta efectiva para perfeccionar los resultados como se ve en la Tabla 10. Se consigue mejorar la precisión en la clasificación un 16% respecto a la mejor obtenida sin optimización.

Tabla 10. Precisión de SVM sin y con optimización de hiperparámetros con Optuna

Parámetro	Descripción	Valores por defecto	Hiperparámetros optimizados con Optuna [27]
`C`	Establece cuánto se desea evitar clasificar erróneamente cada ejemplo de entrenamiento	1,0	10
`gamma`	Está relacionado con el parámetro kernel, indica la región de decisión mediante la similitud entre dos puntos	scale	1,0
`kernel`	Se trata de un tipo de función de similitud, que modifica en funcionamiento del algoritmo	RBF	linear
Precisión		72,46%	88,04%
Tiempo ejecución		0,1 s.	23,2 s.

[27] Mejora un 16% la precisión que sin hiperparámetros.

Importancia de las características

Para determinar la importancia de las características de SVM se tiene en cuenta el atributo "`._coef`" del modelo generado con los parámetros optimizados. Éste atributo contiene los pesos asignados a cada característica de un kernel tipo `linear`. En la Figura 29, se ve como las variables más importantes coinciden con las de los algoritmos anteriores `ST_Slope_Flat` y `ST_Slope_Up`.

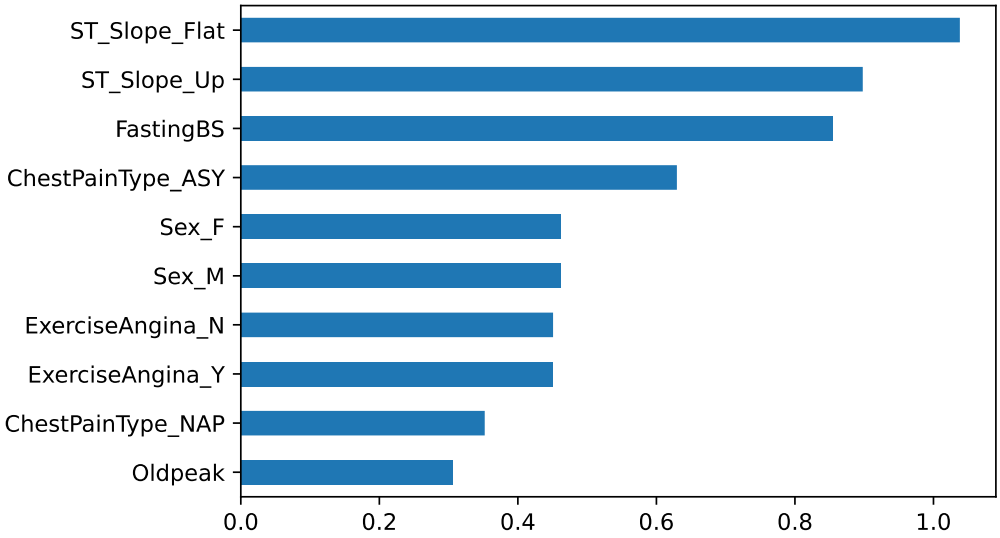

Figura 29. Importancia de características en algoritmo Supported Vector Machines

Matriz de confusión

La Figura 30 nos informa que el algoritmo consigue clasificar mejor las instancias en las que, la clase `HeartDisease` es igual a 1, es decir, aquellas que detectan la enfermedad cardiovascular.

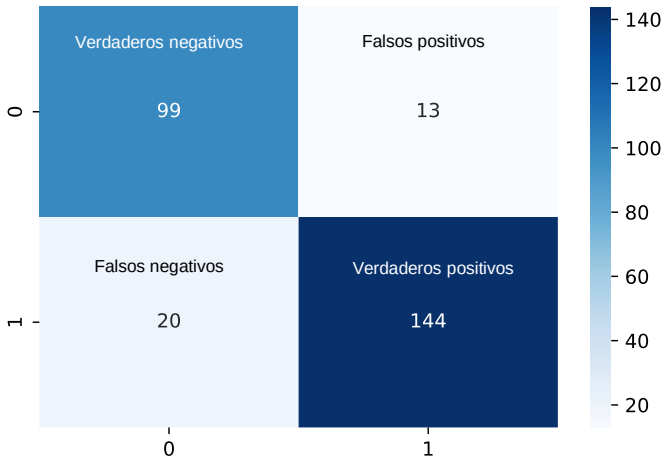

Figura 30. Matriz de confusión de Supported Vector Machines

5.4. Detección de ECV con Deep Learning

El éxito en el uso de redes neuronales en el ámbio cardiológico queda patente tal como se expuso en el apartado 3.2. En el siguiente apartado, se usará el perceptrón multicapa con el objetivo de entrenar un modelo con las instancias del dataset, que sirva para predecir nuevos casos. El algoritmo, encuadrado dentro del aprendizaje supervisado, es proporcionado por las librerías TensorFlow/Keras. Para alcanzar dicho objetivo se realizará un experimento en el que se configurarán varias capas ocultas, cuyas neuronas se configurarán dinámicamente mediante la herramienta Keras Tuner, y se buscarán entre otros parámetros, número óptimo de neuronas para cada capa.

5.4.1 Cuarto experimento: Perceptrón multicapa

Los datos utilizados en este experimento, tienen el mismo preprocesado que los anteriores (Figura 24). Adicionalmente, se realizará la normalización de todos los valores del dataframe eliminando la media (la deja igual a 0) y escalando la varianza de cada característica (la deja igual a 1) mediante el uso de `StandardScaler`, que recodifica todos los valores entre 0 y 1. Tomando para el conjunto de entrenamiento el 70% del dataset y el 30% restante para tests, se configura Keras Tuner con la red neuronal tal como se observa en la Figura 31.

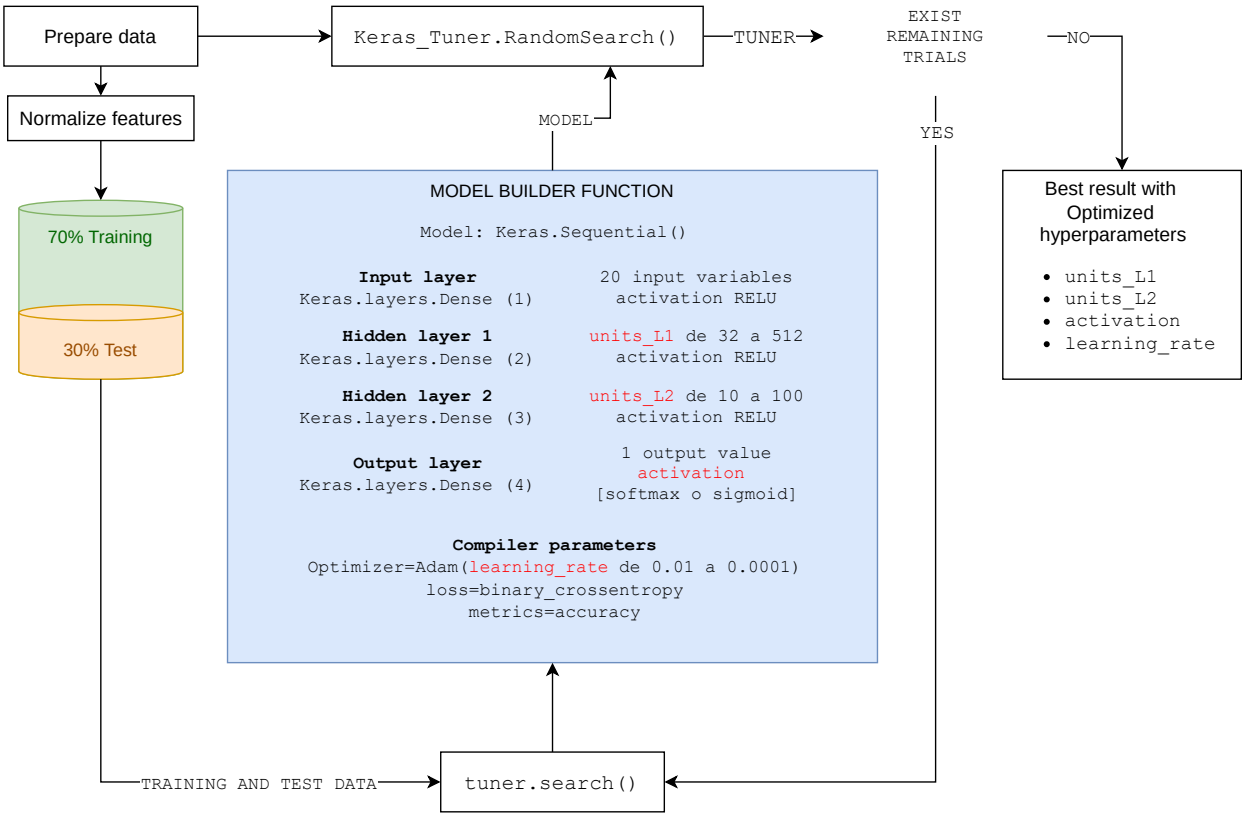

Figura 31. Keras tuner para crear un MLP configurable.

El proceso de optimización de hiperparámetros del MLP usando Keras Tuner nos informa del mejor valor de precisión encontrado, el tiempo total de ejecución del optimizador de Keras_tuner en los diferentes intentos y los parámetros que han propiciado la mejor precisión.

```
Total elapsed time: 00h 03m 51s
Best val_accuracy So Far: 0.9275362491607666
INFO:tensorflow:Oracle triggered exit
Best HYPERPARAMETERS:  {'Neurons_layer_1': 224,
                        'Neurons_layer_2': 40,
                        'Activation_fx': 'sigmoid',
                        'Learning_rate': 0.01}
```

En la Tabla 11 se muestra, comparativamente, el resultado de ejecutar el perceptrón de la librería Scikit-Learn con los parámetros por defecto, respecto a Keras con los hiperparámetros optimizados. Como se aprecia, el uso de Keras mejora la precisión en un 3% respecto al perceptrón sin configurar, llegando hasta 92,75%, la mejor conseguida de entre todos los experimentos realizados.

Tabla 11. Comparación de resultados perceptrón con y sin optimización de parámetros.

Parámetro	Descripción	Valores por defecto SkLearn	Hiperparámetros optimizados con K-Tuner [28]
n_layers	Número de capas del perceptrón	1 Input 1 Hidden 1 Output	1 Input 2 Hidden 1 Output
units	Se refiere al número de neuronas de cada capa oculta.	Hidden = 100	Hidden 1 = 224 Hidden 2 = 40
activation	Se refiere a la función de activación de las neuronas en la capa de salida	softmax	sigmoid
learning_rate	Capacidad para ajustar el peso de los coeficientes de entrada/salida de cada neurona.	0.001	0.01
Precisión		89,13%	92,75%
Tiempo ejecución		1,47 s.	4 s.

[28] Mejora un 3% la precisión que sin hiperparámetros optimizados

5.5 Comparación de modelos Machine y Deep Learning

Tras transformar los datos y aplicar varias configuraciones a cada algoritmo, se observa que el uso de la optimización de los hiperparámetros mejora la precisión en todos ellos. La mayor obtenida es con el perceptrón multicapa, que mejora sensiblemente la registrada en Kaggle[29] con el algoritmo Catboost (90,94%). La Figura 32, muestra la comparación entre algoritmos.

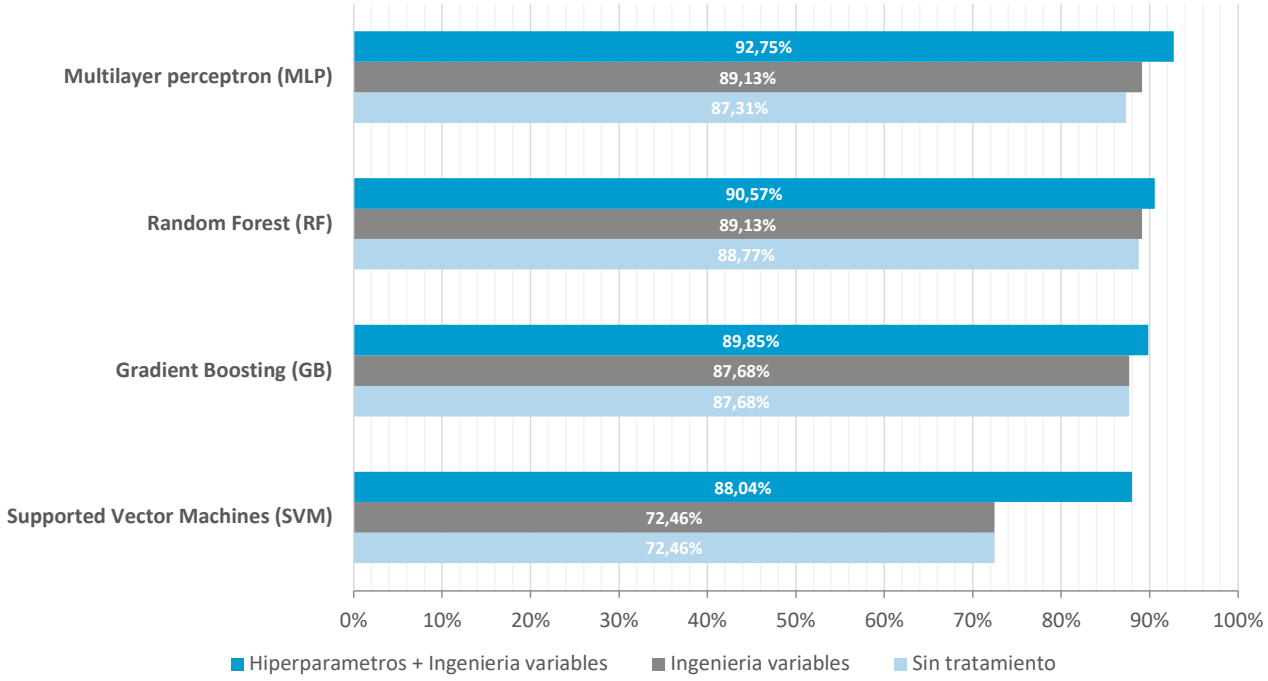

Figura 32. Comparación de precisiones obtenidas en función de técnicas aplicadas.

Respecto a los tiempos de ejecución, tal como se muestra en la Figura 33, Gradient Boosting es el que menos tiempo tarda en ejecutarse, por el contrario, el algoritmo Supported Vector Machines consigue mejorar sustancialmente su clasificación con parámetros optimizados, pero necesita mucho más tiempo de ejecución.

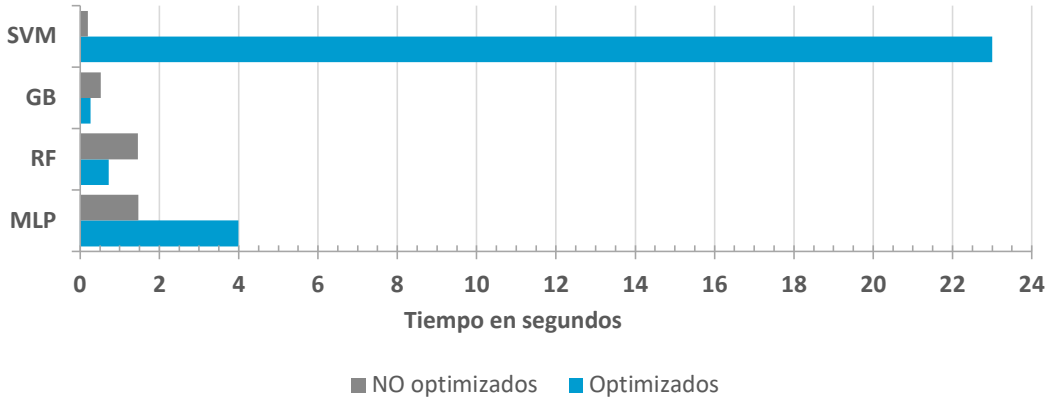

Figura 33. Tiempos de ejecución de los algoritmos de ML y DL

[29] https://www.kaggle.com/kaanboke/beginner-friendly-catboost-with-optuna

5.6. Detección de ECV con IBM Watson Studio

Para el estudio de los datos con ésta herramienta, tal y como se indicó en el punto 4.1, es necesario crear en primera instancia una cuenta gratuita de usuario en la plataforma de IBM Watson Cloud. Una vez hecho ésto, tendremos acceso a la consola a través de la URL https://dataplatform.cloud.ibm.com/home.

5.6.1. Configuración del proyecto

Para acceder a las herramientas de Machine Learning de IBM Watson Studio, se debe crear primero un proyecto. Puede crearse vacío, desde un ejemplo o archivo previo. En éste caso crearemos uno vacío al que llamaremos HeartDisease. En la Figura 34 se observa el proyecto una vez añadidos los elementos de activos, experimentos, flujos y notebooks.

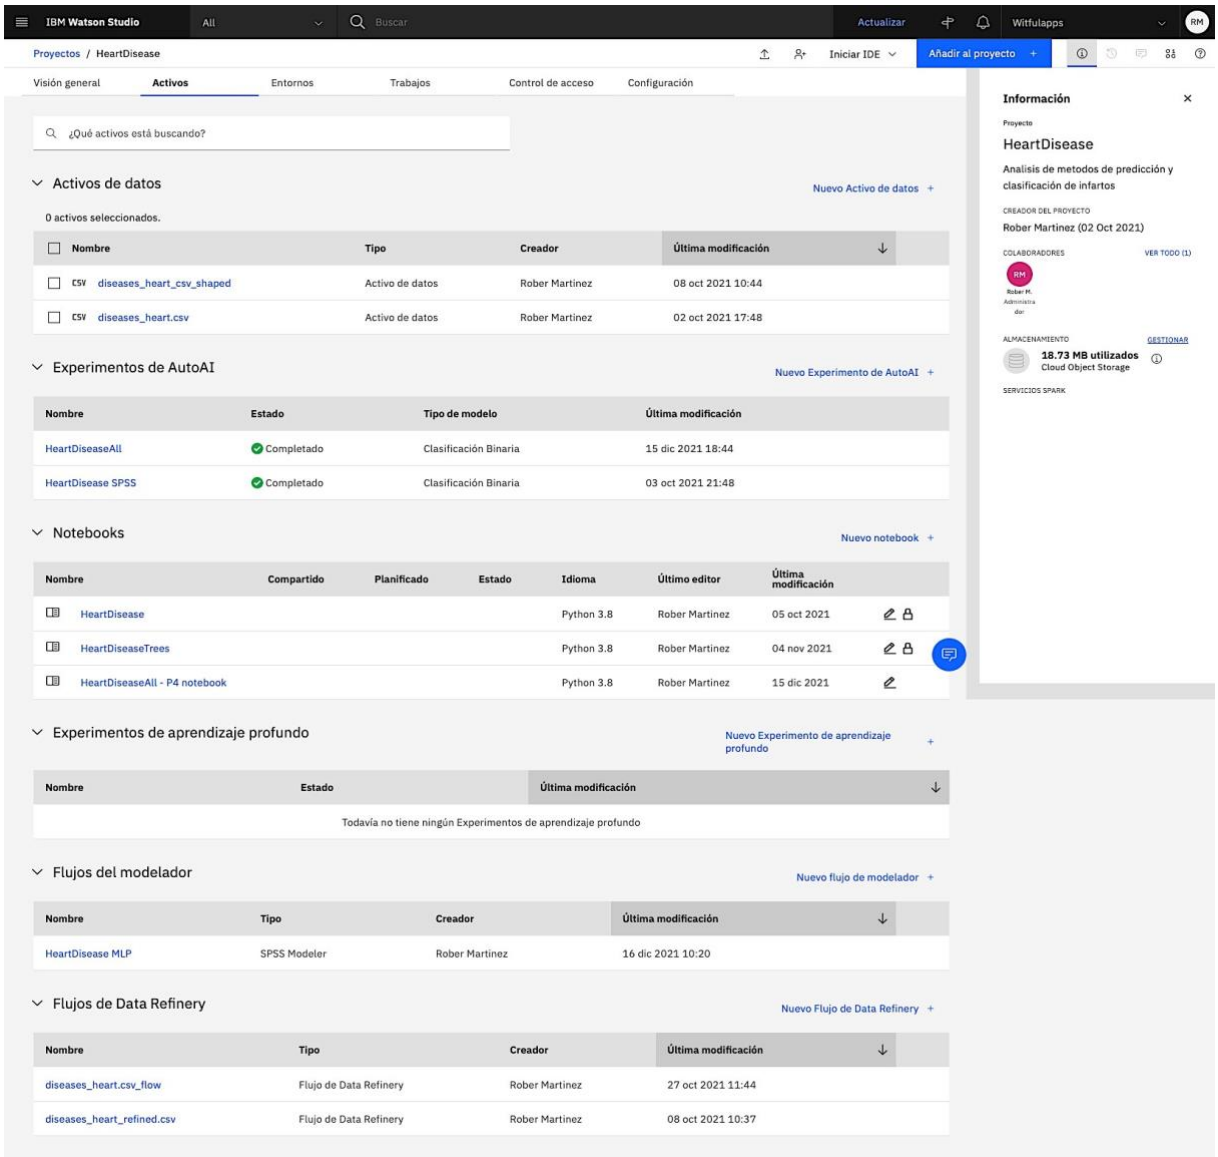

Figura 34. Panel de proyectos / activos de IBM Watson Studio

5.6.2. Preparación y análisis de los datos

Con el proyecto inicializado, en la sección de "Activos" se realizan distintas operaciones:

1. **Cargar dataset**: Aquí cargamos el fichero `.csv` del dataset denominado `diseases_heart.csv` a través de *"+ Nuevo activo de datos"*. En la sección "*Vista previa*", podremos visualizar en forma tabular las características y los datos.

2. **Refinar dataset**: Una ver cargado el dataset, pulsaremos en "*Refinar*". En este punto aplicamos transformaciones sobre los datos como por ejemplo, eliminar duplicados, sustituir valores, concatenar columnas, hacer cálculos…etc. También podemos visualizar estadísticas de los datos en la ficha "*Perfil*", por ejemplo para la variable "`Age`" (Figura 35).

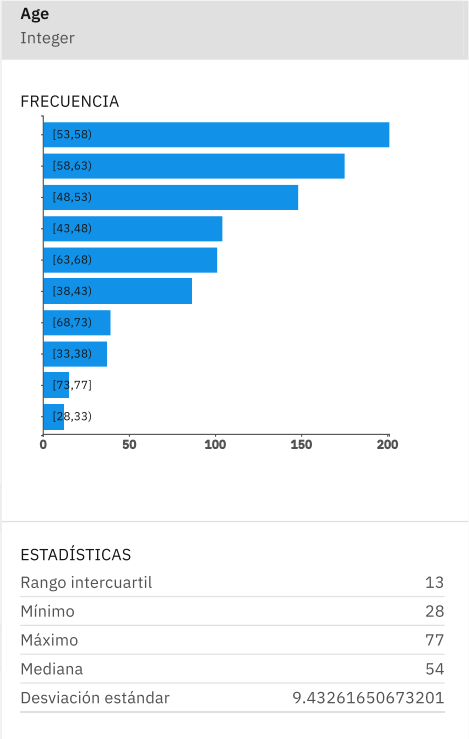

Figura 35. Información estadística de una variable en IBM Watson Studio

Para transformar las columnas categóricas se accede al panel izquierdo "*New step +"* y se aplica una sustitución condicional, para cada valor hay que añadir una condición:

- Para la característica "`Sex`" sustituimos el valor "M" por "1" y el valor "F" por "0".
- Para la característica "`ChestPainType`" el valor "ATA" se codifica "1", "NAP" se codifica "2", "ASY" se codifica "3" y "TA" se codifica "4".
- Para la característica "`RestingECG`" el valor "ST" se codifica "0", "LVH" se codifica "1" y "Normal" se codifica "2".
- Para la característica "`ST_Slope`" el valor "Up" se codifica "0", "Flat" se codifica "1" y "Down" se codifica "2".

Finalmente se seleccionará la opción "*Guardar y crear flujo de trabajo*" indicando el nombre "`diseases_heart_csv_shaped`" y el formato CSV para el crear el nuevo conjunto de datos con las transformaciones indicadas. Los flujos de trabajo son tareas que se ejecutan en segundo plano en Watson, en este caso se trata de crear un nuevo dataset transformado.

El flujo creado aparecerá en el apartado "*Activos*" al final de la pantalla en la sección "*Flujos de Data refinery*" tal como se muestra en la Figura 34 y el nuevo fichero aparecerá en la sección "*Activos de datos*".

3. **Visualización**: Esta ficha permite realizar visualizaciones sobre el dataset de forma sencilla, seleccionando una primero característica y después el tipo de gráfico, tal y como se muestra en la Figura 36 para el atributo "Age". Así mismo a través del menú acciones se pueden descargar en formato imagen png.

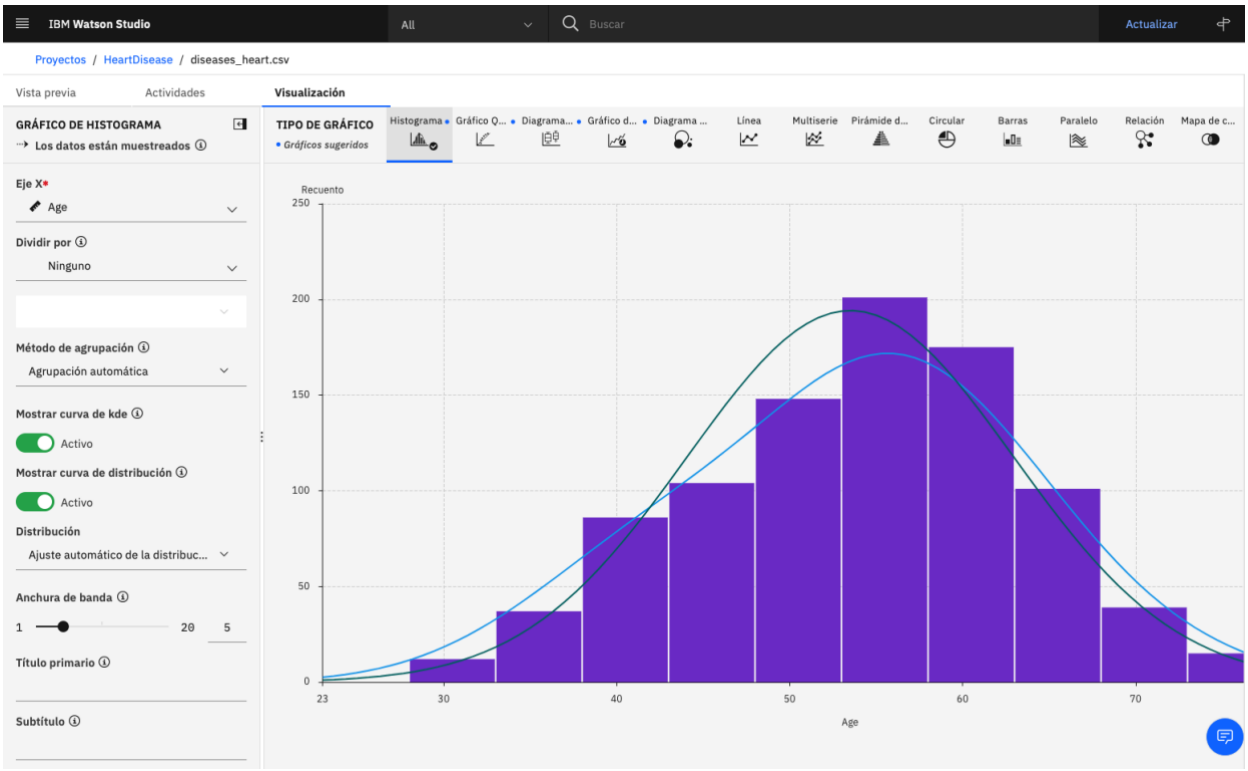

Figura 36. Histograma generado en IBM Watson a partir de característica del dataset

5.6.3. Experimento de AutoAI de Machine Learning

Para ejecutar los algoritmos sobre el conjunto de datos refinado que hemos creado anteriormente, hay que pulsar en la opción "*Nuevo experimento de AutoAI*" y después especificar el nombre del experimento "HeartDiseaseAll" junto a su descripción.

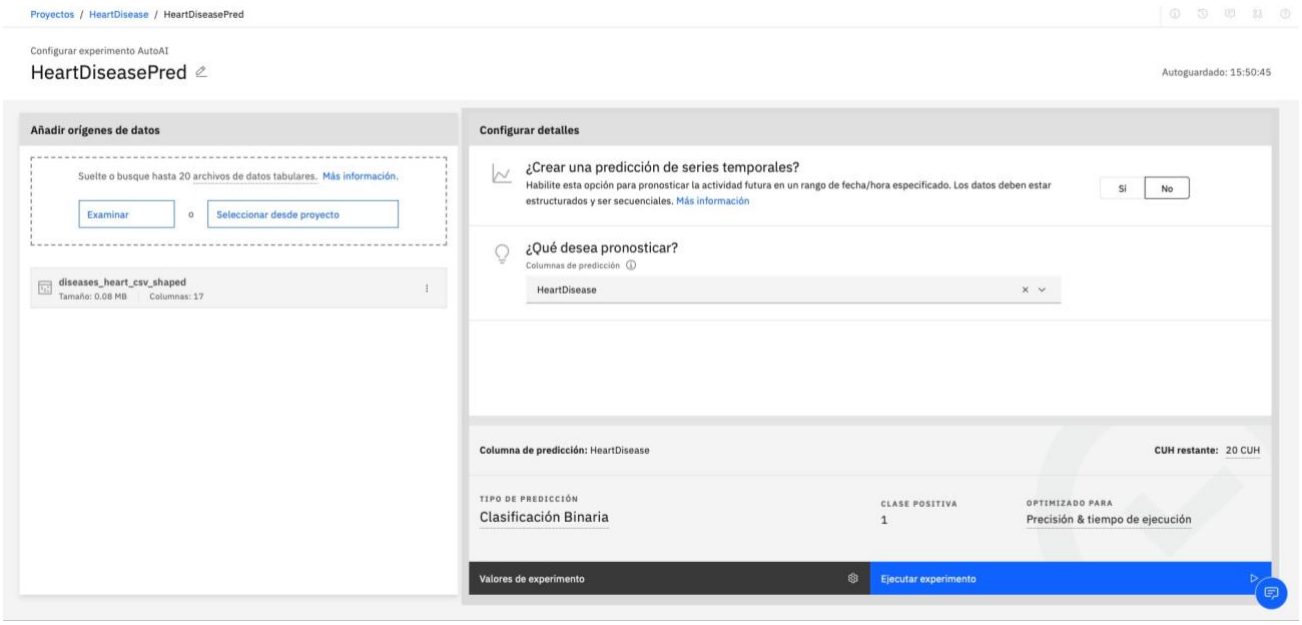

Figura 37. Creación de experimento, configuración y ejecución

Configuración del experimento

Las características técnicas de la máquina virtual donde se ejecutará el experimento vienen pre-establecidas ya que no es posible modificarlas desde una cuenta gratuita, por defecto será una CPU de 8 núcleos y 32 GB de RAM que tiene un consumo de 20 unidades por hora para entrenar modelos; la instancia de Machine Learning por defecto será "WatsonMachineLearning". Con la cuenta gratuita de IBM Watson Studio (Plan Lite) se dispone de 50 unidades de capacidad (CUH) mensuales, se puede ver el uso en la pestaña "*Entornos*" dentro del proyecto.

A continuación se debe añadir el origen de los datos, bien desde el ordenador o seleccionando del proyecto un archivo de los "Activos de datos", seleccionaremos "`diseases_heart_csv_shaped.csv`" que es el que hemos refinado. Tras esto, Watson Studio nos pedirá que indiquemos el campo de nuestro dataset que deseamos pronosticar, y reseñaremos "HeartDisease" que es la clase que determina si se padece o no una enfermedad cardiovascular.

Para especificar los parámetros con los que se ejecutarán los algoritmos que seleccionemos, pulsamos sobre el botón "*Valores del experimento*" (Figura 37). En la pantalla que aparece a continuación, introducimos la siguiente información:

1. Opción "*Valores de predicción*"
    a. Seleccionar "Clasificación binaria".
    b. Clase positiva "1".
    c. Métrica optimizada "Precisión".
    d. Selección de algoritmos optimizados "Puntuación y tiempo de ejecución".
    e. Algoritmos a incluir clasificadores "Aumento de gradiente", "Bosque aleatorio", "SVM de instantáneas" y "árboles adicionales".
    f. Algoritmos a utilizar "2".
2. Opción "*Origen de datos*"
    a. Activar "Descartar filas duplicadas".
    b. Activar "Filas de submuestra", seleccionar "Porcentaje" e importe "80".
    c. El resto de parámetros se dejan los que vienen por defecto.
3. Opción "*Tiempo de ejecución*", se dejan los parámetros por defecto.

Ejecución del experimento

Una vez configurado, pulsamos sobre el botón "*Ejecutar experimento*" para entrenar los modelos con los datos del dataset en base a los algoritmos que hemos seleccionado. El sistema empezará a ejecutar los algoritmos siguiendo una serie de pasos que se pueden observar en la siguiente pantalla denominada "Resumen del experimento" (Figura 38). El experimento ejecutará secuencialmente cada algoritmo aplicando siempre los mismos pasos, visibles en la sección "*Mapa de progreso*". Finalmente se mostrarán los modelos creados.

- **Pasos comunes** a todos los algoritmos (preparación inicial del dataset):
    1. Carga del conjunto de datos.
    2. División de los datos en conjunto de test y entrenamiento.
    3. Procesado de datos de entrenamiento.
    4. Preprocesado.
    5. Selección del modelo.

- Pasos que se ejecutan **por cada algoritmo**:
    1. Instanciación del clasificador.
    2. Optimización de hiperparámetros

3. Ingeniería de características (análisis de componentes principales, selección de característica univariada, Redondeo).
4. Optimización de hiperparámetros.

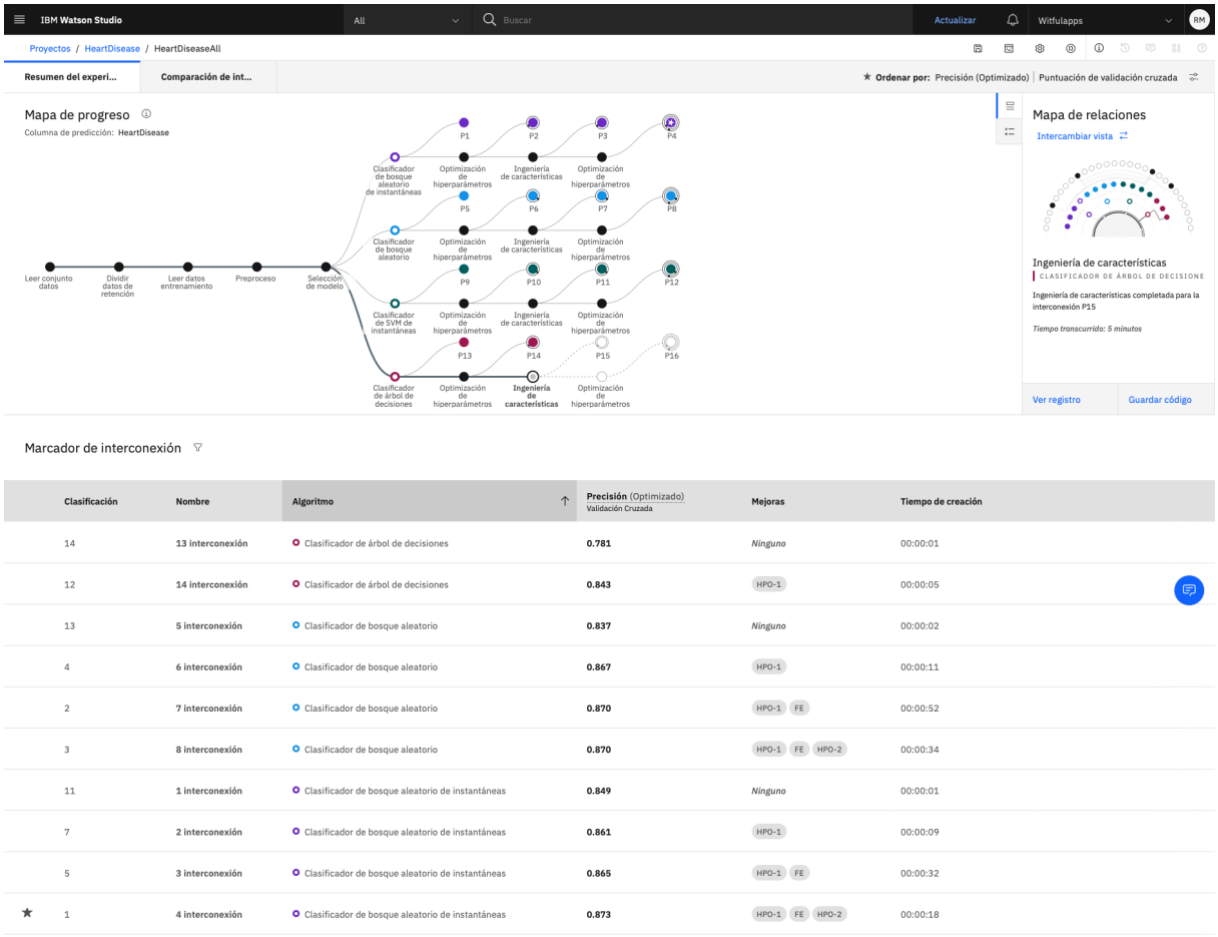

Figura 38. Salida de IBM Watson tras la ejecución del experimento de clasificación

Interpretación de los resultados

La ejecución del experimento completo tuvo una duración de 6 minutos, y en la pantalla de resultados se pueden observar las precisiones de los algoritmos, la duración en la ejecución, las mejoras aplicadas a los datos y la posición de ranking respecto a los demás algoritmos.

El algoritmo con mejor resultado es el “Clasificador de bosque aleatorio de instantáneas” (Random Forest) con un 87,3% de precisión, y sobre el que se aplicaron ingeniería de características y optimización de hiperparámetros. En la lista aparece marcado con una estrella. Este valor no mejora del conseguido en el primer experimento del punto 5.3.2 donde se obtuvo más de 90% de precisión en la clasificación, y está ligeramente por debajo del obtenido en Kaggle.

Al hacer click sobre cualquier elemento de la lista de resultados, obtenemos la información del modelo, de las características con más importancia como se ve en la Figura 39, donde se observa que `ST_Slope` es la más importante y también nos informa de la matriz de confusión representada en la Figura 40.

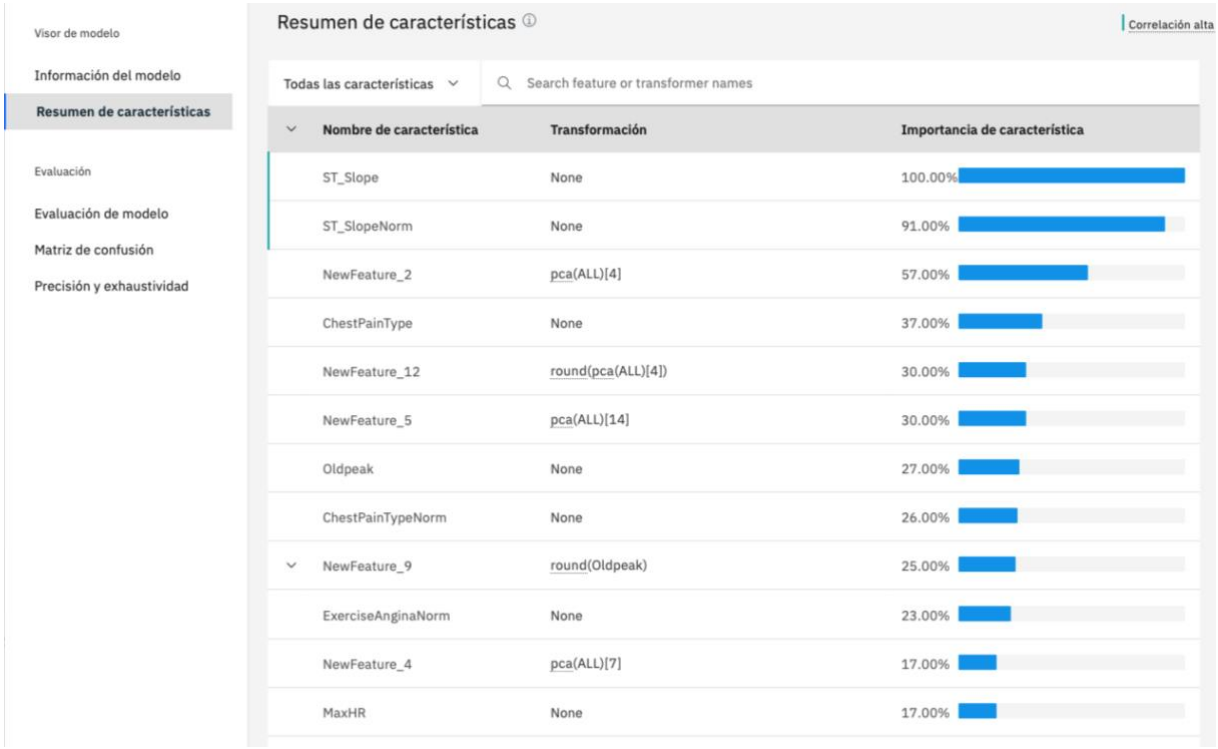

Nombre de característica	Transformación	Importancia de característica
ST_Slope	None	100.00%
ST_SlopeNorm	None	91.00%
NewFeature_2	pca(ALL)[4]	57.00%
ChestPainType	None	37.00%
NewFeature_12	round(pca(ALL)[4])	30.00%
NewFeature_5	pca(ALL)[14]	30.00%
Oldpeak	None	27.00%
ChestPainTypeNorm	None	26.00%
NewFeature_9	round(Oldpeak)	25.00%
ExerciseAnginaNorm	None	23.00%
NewFeature_4	pca(ALL)[7]	17.00%
MaxHR	None	17.00%

Figura 39. Detalle de importancia de características.

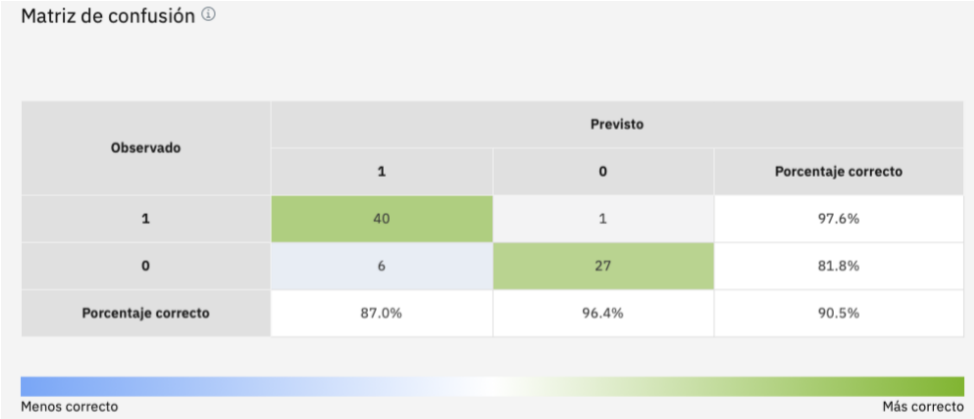

Observado	Previsto		
	1	0	Porcentaje correcto
1	40	1	97.6%
0	6	27	81.8%
Porcentaje correcto	87.0%	96.4%	90.5%

Figura 40. Matriz de confusión tras ejecución del experimento AI.

Cualquier resultado obtenido tras las ejecución del experimento, se puede exportar a un Notebook para ver las operaciones y configuración que se ha ido creando automáticamente en Python por IBM Watson Studio, y en su caso utilizar el código en otros proyectos o simplemente ver como lo ha hecho. Al exportarlo, aparecerá en la pantalla de activos en la sección "*Notebooks*".

5.6.4. Experimento de SPSS Modeler (red neuronal)

Para realizar el experimento con una red neuronal en IBM Watson Studio, debemos crear un nuevo "*Flujo de modelador*" que llamaremos "HeartDisease MLP". En la consola de modelado que se ve en la Figura 41, tenemos que realizar una serie de pasos para clasificar con una red neuronal.

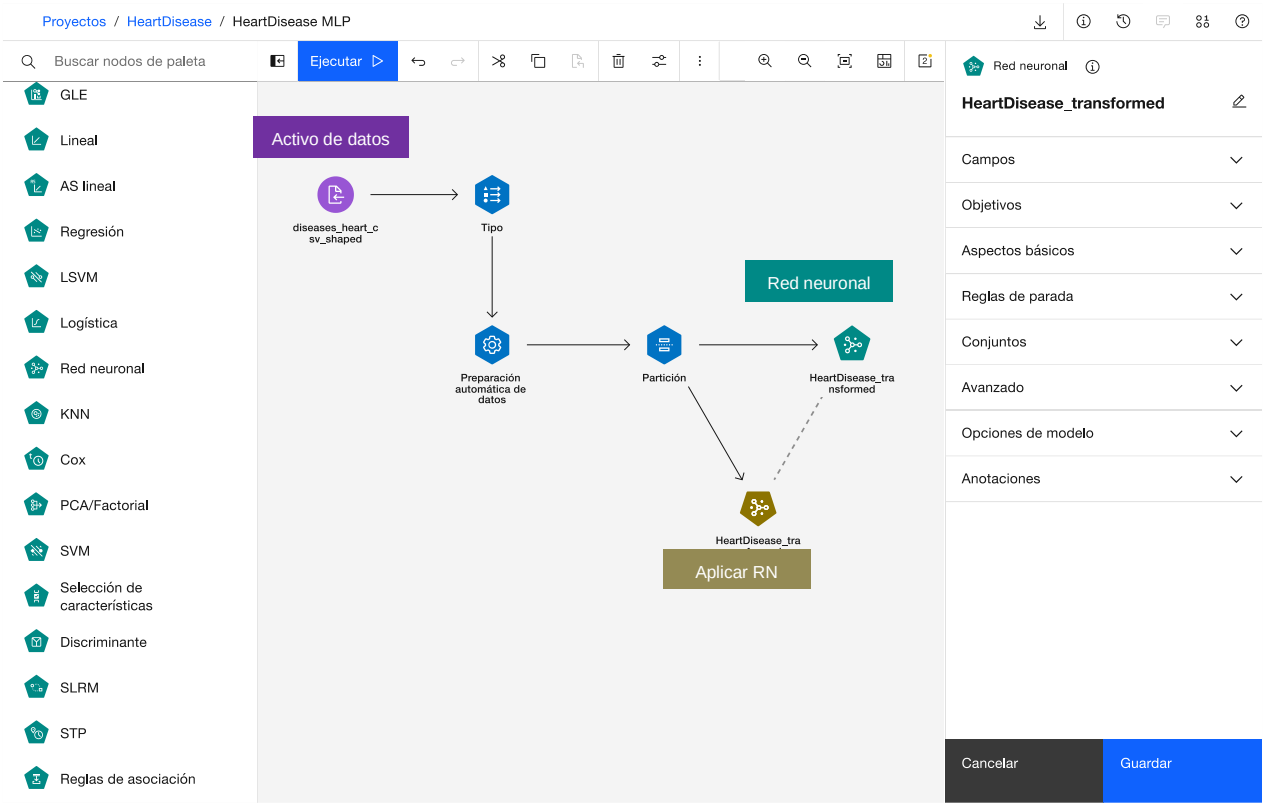

Figura 41. Configuración de flujo de modelado para clasificar con red neuronal

Configuración del flujo de modelado

Desde el panel izquierdo de la consola, es necesario arrastrar distintos "nodos" de flujo a la parte central de la consola. Cada nodo realizará una operación distinta sobre los datos de entrada, siendo el último nodo la red neuronal que recibe los datos tras todas las transformaciones anteriores.

Para este experimento y de cara a mostrar la facilidad de configuración de un perceptrón con esta herramienta, se utilizará la configuración por defecto de los nodos, excepto en el nodo partición. Para realizar un flujo completo será necesario añadir desde el panel izquierdo:

1. Un nodo "**Activo de datos**" (color morado) para importar el conjunto de datos. Aquí seleccionaremos el fichero "`diseases_heart_csv_shaped`".

2. Un nodo "**Tipo**" para definir metadatos de las características, incluyendo una selección de atributos de destino para la clasificación.
3. Un nodo "**Preparación automática de Datos**", para preparar los datos en la elaboración del modelo.
4. Un nodo "**Partición**", se establece el porcentaje de instancias para entrenar y test.
5. Un nodo "**Red Neuronal**" (color verde) para crear y ejecutar el modelo. En este nodo se pueden configurar el número de capas, la función base, los objetivos…etc.

Para enlazar los nodos, será necesario con el ratón, arrastrar desde la flecha superior de cada nodo al nodo del paso siguiente.

Ejecución del flujo de modelado

Para ejecutar el flujo se pulsa en el botón de la barra de herramientas "*Ejecutar*", y tras unos instantes aparece el nodo de color ocre que contendrá el modelo y un análisis de los datos que ha clasificado. Los resultados obtenidos, se muestran al pulsar con el botón derecho del ratón y en el menú contextual se selecciona "Ver modelo" para verificar los resultados.

Evaluación de los resultados

En la sección "*Evaluación del modelo*" se observa que se ha obtenido una precisión del 89,7%, inferior a la obtenida con las librerías TensorFlow y Keras. La matriz de confusión representada en la Figura 42 nos dice que ha conseguido clasificar correctamente más instancias de la clase "con enfermedad cardiovascular (1)" que de la clase 0 ().

Matriz de confusión

Objetivo: HeartDisease_transforr

Observado	Pronosticado		
	0	1	Porcentaje correcto
0	162	22	88.0%
1	24	240	90.9%
Porcentaje correcto	87.1%	91.6%	89.7%

Menos correcto Más correcto

Figura 42. Matriz de confusión perceptrón IBM Watson Studio

En la pestaña lateral "*Información del modelo*" aparece la estructura de la red neuronal que ha generado el modelo y que se muestra en la Tabla 12, modelo que, respecto a la red neuronal configurada con Keras_Tuner tiene peor porcentaje de precisión. Además difieren el número de capas ocultas, el número de neuronas y las funciones de activación utilizadas.

Tabla 12. Parámetros perceptron multicapa IBM Watson Studio

Campo objetivo	HeartDisease
Método de generación de modelos	MLP
Tipo de modelo	Clasificación
Número de predictores	11
Número de capas ocultas	1
Número de neuronas en la capa oculta	7
Función de activación en la capa oculta	Tangente hiperbólica (tanh)
Número de neuronas en la capa de salida	2
Función de activación en la capa de salida	Softmax

Importancia de las características

En la siguiente figura como se puede observar, se ha detectado como característica más importante respecto de la predicción/precisión `ST_SlopeNorm`, que coincide con la de los algoritmos de los experimentos anteriores.

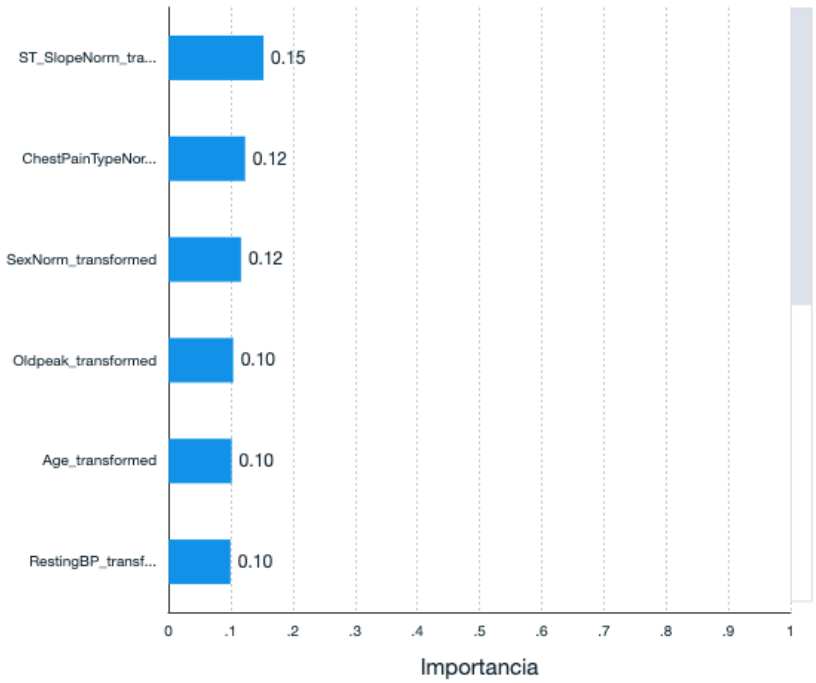

Figura 43. Importancia características Perceptron IBM Watson Studio

6. Comparativa de las tecnologías utilizadas

En este trabajo se han estudiado los factores de riesgo que permiten detectar una cardiopatía a través de un dataset, también se han realizado varios experimentos sobre el conjunto de datos con las herramientas de programación más utilizadas en el ámbito de Machine Learning (ML) y Deep Learning (DL). Por otro lado, también se ha hecho uso de un framework como IBM Watson Studio orientado a la ciencia de datos, donde se han desarrollado experimentos equivalentes a los realizados programáticamente en Python, con la intención de comparar los resultados y el esfuerzo realizado.

El objetivo principal además de demostrar la idoneidad de unos algoritmos sobre otros, es demostrar si herramientas como IBM Watson Studio ofrecen buenos resultados en el campo de la ciencia de datos, y que ventajas podría tener hoy en día su uso en entornos de producción que manejan grandes cantidades de información de diferente índole como en el campo de la salud, ya sean hospitales, centros médicos o de investigación donde la explotación de los datos en primera instancia, no siempre se realiza por equipos de ingenieros, analistas o científicos de datos. A continuación se expondrán los resultados obtenidos de la ejecución de los experimentos en ambas tecnologías, se evaluará la dificultad para realizar las distintas tareas y comparará el marco tecnológico necesario para la acometerlas.

6.1. Resultados obtenidos de ML y DL

En la siguiente tabla se muestran los algoritmos que han conseguido los mejores resultados, la precisión obtenida tras la configuración y entrenamiento y el tiempo de ejecución.

Tabla 13. Comparativa de precisión y tiempo de ejecución de algoritmos

Característica	IBM Watson Studio	Python (TensorFlow/Keras)
Mejor clasificador de ML	Random Forest	Random Forest
Mejor precisión del modelo ML	87,30%	90,57%
Tiempo de creación del modelo ML	18 s.	0,72 s.
Mejor clasificador de DL	Perceptrón multicapa	Perceptrón multicapa
Mejor precisión del modelo DL	89,7%	92,70%
Tiempo de creación del modelo DL	2 s.	4 s.

6.2. Requisitos técnicos

A continuación se muestran los requisitos técnicos necesarios para hacer uso de una y otra plataforma, desde la carga de los datos hasta la generación de los resultados.

Tabla 14. Comparación de requisitos IBM Watson vs Python TensorFlow/Keras

Requisitos	IBM Watson Studio	Python (TensorFlow/Keras)
Hardware	No es necesario en el entorno web, la computación se realiza en máquinas virtuales dimensionadas en la nube.	Máquina con CPU compatible con instrucciones AVX (TensorFlow > v1.6) Tarjetas gráficas NVidia con GPU con soporte para CUDA (solo en Windows y Ubuntu)
Software	IBM Watson Studio tiene herramientas integradas con muchos de los paquetes software de ML y DL, así como herramientas para el análisis y visualización de datos.	**Herramientas y librerías ML y DL** - PyCharm IDE - Python 3.6 a 3.9 - Pip > 19.0 (>20.3 en MacOS) - TensorFlow 2.7.0 - Keras 2.7.0 - Scikit-Learn 1.0.1 - Keras tuner 1.1.0 - Jupyter Notebook 1.0.0 - Pandas 1.3.4 y Numpy 1.21.4 - Numba 0.54.1 - Optuna 2.10.0 **Herramientas de ETL** - Microsoft Excel **Herramientas y librerías de visualización** - Seaborn 0.11.2 - Matplotlib 3.5.0 - Shap 0.40.0 - Microsoft Excel
Sistema operativo	Está integrado en la máquina virtual que se ejecuta en la nube	- Linux 64 bits (Ubuntu > 16.0) - MacOS 64 bits (Sierra o superior) - Windows 7 64 bits o posterior con librería visual studio C++ '15-'19.
Puesta en marcha	Creación de cuenta en IBM Cloud y selección de la localización del data center cloud. La configuración está completamente integrada dentro de la consola web. Se hace por medio de clicks de ratón, no es necesario programar nada si no se desea.	- Instalación del software y importación de los paquetes necesarios para cada algoritmo. - Configuración de las herramientas de visualización con los datos generados. - Programación de los algoritmos y configuración de las librerías y modelos.

6.3. Funcionalidad

Desde el punto de vista práctico, el uso de IBM Watson Studio o de Python (con el resto de librerías de ML y DL) estará condicionado por las necesidades del analista o científico de datos que trabaje en una organización con más o menos recursos económicos. La idoneidad de cada una de las tecnologías se basará también en las ventajas y desventajas técnicas reflejadas en el punto anterior y también en otros que se detallan a continuación[30].

6.3.1. IBM Watson Studio

Ventajas

- Permite la integración con muchas API de IBM como por ejemplo reconocimiento de voz, de imágenes o análisis de personalidad.
- El modelador SPSS y el modelo de red neuronal permite construir entornos *sin necesidad de programar*, a científicos de datos que pueden construir soluciones rápidamente. En general es fácil de usar evita la necesidad de tener un equipo de científicos de datos.
- El desarrollo de pruebas de concepto basado en metodologías y buenas prácticas en la implementación, permiten un mínimo reprocesamiento.
- Los modelos de Watson Studio obedecen a las mejores prácticas, lo que significa que están sujetos a menos errores humanos.
- El despliegue del sistema completo dentro de la infraestructura de IBM, exige una mínima administración, provee robustez y seguridad, además de que escalar las soluciones es relativamente sencillo.

Inconvenientes

- La interfaz de usuario de Watson Studio no siempre es intuitiva, fundamentalmente cuando se trata de requisitos y configuraciones específicas.
- La estrecha integración con las API de IBM también significa menor capacidad para integrarse con fuentes de datos y API de terceros; por ejemplo soporte de MySQL.
- La versión de pago, que explota todo el potencial de Watson, tiene un costo elevado, por lo que solo las empresas con recursos pueden permitírselo.

[30] https://www.trustradius.com/compare-products/anaconda-vs-ibm-watson-studio

6.3.2. Python con librerías de ML y DL

Ventajas

- Permite la integración con otras herramientas de terceros como Jupyter, Spyder, bases de datos MySQL, MongoDB…etc.
- Existe una gran cantidad de librerías de todo tipo, para procesamiento de imágenes, video, manejo de textos, imágenes…etc.
- Enorme comunidad de desarrolladores de los que aprender y obtener ayuda en caso de tener problemas con ciertas librerías.
- La integración de librerías de alto nivel como Keras y los Estimadores, hacen muy fácil para un principiante empezar a trabajar con redes neuronales.
- En líneas generales, la curva de aprendizaje de TensorFlow no es demasiado grande en comparación con todos los beneficios obtenidos, además es posible aprovechar el potencial de las GPU para desarrollar modelos pesados.
- Soporta prácticamente todos los algoritmos de Deep Learning así como las últimas arquitecturas de transformadores.

Inconvenientes

- Para realizar cualquier experimento es necesario programar líneas y líneas de código, lo cual ocupa bastante tiempo hasta que se obtiene un modelo productivo.
- Para los perfiles que no son ingenieros, existen partes de las API que son poco intuitivas por lo que es complicado comprender algunos conceptos a la hora de desarrollar soluciones.
- La ejecución en determinadas máquinas con pocos recursos de CPU o memoria, puede hacer que el rendimiento de los algoritmos decaiga.
- Realizar visualizaciones interactivas sobre los datos, es más complicado que con IBM Watson Studio.

7. Conclusiones

La principal conclusión obtenida tras realizar el trabajo, es que hoy en día hay herramientas con las que es relativamente fácil contribuir a la generación de conocimiento en el ámbito de la salud. Los modelos predictivos generados dentro de el campo del aprendizaje automático, son capaces del reconocimiento, análisis y detección de patrones sobre grandes volúmenes de datos y ayudan a clasificar en éste caso, pacientes, en función de unas variables médicas, lo cual es de total ayuda para los médicos o especialistas en su toma de decisiones. Los estudios realizados con anterioridad en distintas áreas de la cardiología utilizando técnicas de ciencia de datos ya arrojaban buenos resultados, en éste trabajo además, se han pretendido utilizar métodos como la optimización de hiperparámetros y la ingeniería de características. En líneas generales, el uso de optimizadores de parámetros para la generación de los modelos, permite mejorar la precisión en la clasificación sin penalizar excesivamente el tiempo de ejecución. Tal como se ha puesto de manifiesto, los algoritmos clasificadores basados en árboles son efectivos y que la buena fama de Random Forest está demostrada en los experimentos realizados aquí. Las diferencias encontradas en este trabajo tras la aplicación de técnicas de Machine Learning y Deep Learning, son mínimas aunque el uso de librerías como TensorFlow y Keras que vienen a ser el estándar de facto en el desarrollo IA en la actualidad, han demostrado ofrecer mejores resultados.

Por otro lado, era también intención dar una visión sucinta del desarrollo necesario para acometer experimentos empleando técnicas de programación en Python con las librerías de ML y DL, así como presentar IBM Watson Studio para realizar las mismas tareas, con el fin de comparar la facilidad de uso. Gracias a ello, se puede concluir también que, el uso de IBM Watson es adecuado para entornos donde se necesita un rápido estudio de los datos y/o visualizaciones intuitivas, especialmente en entornos como el de la medicina, donde no se suele disponer de perfiles técnicos entre la plantilla que puedan sumergirse en el mundo de la programación. Python con TensorFlow, Keras y Scikit-Learn, seguirán siendo por su versatilidad, potencia y eficacia ideales para desarrollar soluciones mucho más complejas y personalizadas, capaz de ser manejadas por ingenieros expertos en ciencia de datos.

Finalmente indicar que, si se hubiera dispuesto de un dataset con un enfoque poblacional más concreto, o con datos relativos a grupos étnicos / raciales, se hubiera podido ampliar éste estudio incluyendo interesantes predicciones a nivel sociológico.

7.1. Líneas de trabajo futuro

Realizar la captura de información relativa a factores de riesgo cardiovascular de diferentes fuentes de datos con el fin de comprobar la utilidad de los modelos desarrollados. Así mismo se podría crear un nuevo conjunto de datos aleatorio, utilizando datos estadísticos relativos a los factores de riesgo cardiovascular padecidos por parte población española, generando una muestra representativa de una población o provincia y teniendo en cuenta los hábitos y costumbres comunes de esa región.

Sería interesante que todo el sistema nacional de salud volcara en tiempo real, datos médicos relativos a diagnósticos que incluyen los factores de riesgo cardiovascular, en una base de datos MongoDB y al mismo tiempo en una cola Kafka. Éste planteamiento abarcaría la posibilidad de integrar los algoritmos de inteligencia artificial desarrollados en este trabajo, en Spark mediante pySpark y utilizar en lugar del dataset, la cola Kafka donde se van insertando los datos, de forma que se vayan recalculando en tiempo real los modelos y generando las predicciones. El resultado en el otro extremo, sería la generación de cuadro de mando para la alta genencia médica, donde la herramienta de visualización Tableau conectaría con Spark, para actualizar en tiempo real las visualizaciones.

Dado que la potencia de la herramienta IBM Watson Studio va mucho más allá de la expuesta en este trabajo, sería interesante utilizarla para entrenar modelos con imágenes de ecocardiografías o tomografías computerizadas del corazón, donde se aprecien signos de enfermedades cardiovasculares. Dichas imágenes servirían para entrenar un modelo basado en redes neuronales convolucionales (CNN) de cara a predecir posibles enfermedades del corazón.

9. Bibliografía

Ahmad, T., Lund, L. H., Rao, P., Ghosh, R., Warier, P., Vaccaro, B., . . . Desai, N. R. (2018). *Machine Learning Methods Improve Prognostication, Identify Clinically Distinct Phenotypes, and Detect Heterogeneity in Response to Therapy in a Large Cohort of Heart Failure Patients.* Obtenido de Journal of the American Heart Association: https://doi.org/10.1161/JAHA.117.008081

Beckerman, J. (2 de Julio de 2020). *Heart Disease and Lowering Cholesterol*. Obtenido de https://www.webmd.com/heart-disease/guide/heart-disease-lower-cholesterol-risk

Budzianowski, J., Hiczkiewicz, J., Burchardt, P., Pieszko, K., Rzeźniczak, J., Budzianowski, P., & Korybalska, K. (2019). Predictors of atrial fibrillation early recurrence following cryoballoon ablation of pulmonary veins using statistical assessment and machine learning algorithms. *Heart and vessels*, 34(2), 352–359. Obtenido de Heart and vessels: https://doi.org/10.1007/s00380-018-1244-z

Burns, E., & Buttner, R. (2 de Abril de 2021). *Left Ventricular Hypertrophy*. Obtenido de https://litfl.com/left-ventricular-hypertrophy-lvh-ecg-library/

Centers for disease Control and Prevention. (9 de Diciembre de 2019). *Know your risk for Heart Disease*. Obtenido de https://www.cdc.gov/heartdisease/risk_factors.htm

Char, D., Shah, N., & Magnus, D. (2018). Implementing Machine Learning in Health Care - Addressing Ethical Challenges. En *The New England journal of medicine* (págs. 378(11), 981–983.).

Christian F. Baumgartner, L. M. (2017). *An Exploration of 2D and 3D Deep Learning Techniques for Cardiac MR Image Segmentation.* Obtenido de arxiv.org: https://arxiv.org/pdf/1709.04496.pdf

Dilsizian SE, S. E. (16 de Enero de 2014). *Artificial intelligence in medicine and cardiac imaging: harnessing big data and advanced computing to provide personalized medical diagnosis and treatment.* Obtenido de PubMed.gov: https://pubmed.ncbi.nlm.nih.gov/24338557/

Ebrahimzadeh, E., Kalantari, M., Joulani, M., Shahraki, R. S., Fayaz, F., & Ahmadi, F. (10 de Agosto de 2018). *Prediction of paroxysmal Atrial Fibrillation: A machine learning based approach using combined feature vector and mixture of expert classification on HRV signal.* Obtenido de PubMed.gov: https://med.mahidol.ac.th/ceb/sites/default/files/public/pdf/Repository/Prediction%20of

%20paroxysmal%20Atrial%20Fibrillation%20A%20machine%20learning%20based%20approach%20using%20combined%20feature%20vector%20and%20mixture%20of%20expert%20classification%2

Elias, E., Maede, K., Mohammadamin, J., Reza, S. S., Farahnaz, F., & Fereshteh, A. (2018). Prediction of paroxysmal Atrial Fibrillation: A machine learning based approach using combined feature vector and mixture of expert classification on HRV signal. En *Computer Methods and Programs in Biomedicine* (págs. 53-67).

Ginghina, C., Ungureanu, C., Vladaia, A., Popescu, B. A., & Jurcut, R. (2009). *The electrocardiographic profile of patients with angina pectoris.* Obtenido de Journal of medicine and life, 80–91.: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5051487/

González, L. (4 de Febrero de 2021). *Enfermedades cardiacas frecuentes*. Obtenido de Quironsalud.es: https://www.quironsalud.es/blogs/es/corazon-salud/enfermedades-cardiacas-frecuentes

Inan, O. T., Baran Pouyan, M., Javaid, A. Q., Dowling, S., Etemadi, M., Dorier, A., . . . Klein, L. (2018). *Novel Wearable Seismocardiography and Machine Learning Algorithms Can Assess Clinical Status of Heart Failure Patients.* Obtenido de Circulation Heart failure: https://doi.org/10.1161/CIRCHEARTFAILURE.117.004313

Irene, S., Sebastian, L., Wojciech, S., & Robert, M. (2016). Interpretable deep neural networks for single-trial EEG classification. En *Journal of Neuroscience Methods* (págs. 141-145).

Kotsis, V., Jordan, J., Micic, D., . . . Stabouli. (2018). Obesity and cardiovascular risk: a call for action from the European Society of Hypertension Working Group of Obesity, Diabetes and the High-risk Patient and European Association for the Study of Obesity: part A: mechanisms of obesity induced hypertension. En *Obesity and cardiovascular risk: a call for action from the European Society of Hypertension Working Group of Obesity, Diabetes and the High-risk Patient and European Association for the Study of Obesity: part A: mechanisms of obesity induced hypertension* (Vol. 36, págs. 1427–1440). Journal of hypertension. Obtenido de Journal of hypertension: https://doi.org/10.1097/HJH.0000000000001730

Lancaster, M. C., Salem Omar, A. M., Narula, S., Kulkarni, H., Narula, J., & & Sengupta, P. P. (2019). Phenotypic Clustering of Left Ventricular Diastolic Function Parameters: Patterns and Prognostic Relevance. En *JACC Cardiovascular imaging.* Obtenido de PubMed: https://doi.org/10.1016/j.jcmg.2018.02.005

Lim, Y. C., Teo, S. G., & Poh, K. K. (2016). *ST-segment changes with exercise stress*. Obtenido de Singapore Medical Journal: http://www.smj.org.sg/article/st-segment-changes-exercise-stress

Mateos-Cáceres, P. J. (2009). Marcadores sanguíneos utilizados en el diagnóstico y pronóstico del riesgo cardiovascular. En P. J. Mateos-Cáceres, *Libro de la salud cardiovascular del Hospital Clínico San Carlos y la Fundación BBVA* (págs. 232-233). Fundación BBVA. Obtenido de https://www.fbbva.es/publicaciones/libro-de-la-salud-cardiovascular-del-hospital-clinico-san-carlos-y-la-fundacion-bbva/

Medved, D., Ohlsson, M., Höglund, P., Andersson, B., Nugues, P., & Nilsson, J. (2018). *Improving prediction of heart transplantation outcome using deep learning techniques.* Obtenido de Scientific Reports.

Mill, J. A. (6 de Junio de 2016). *Under pressure: How blood pressure affects heart disease risk*. Obtenido de https://utswmed.org/medblog/high-blood-pressure-heart-disease/#:~:text=For%20the%20average%20person%20who,at%20risk%20for%20heart%20disease.%C3%A7

Millaruelo Trillo, J. M. (2002). *¿La diabetes tipo 2 debería diagnosticarse y tratarse como una enfermedad cardiovascular?* Obtenido de http://scielo.isciii.es/scielo.php?script=sci_arttext&pid=S1131-57682002000800005&lng=es&tlng=es.

North, B. J. (2012). The intersection between aging and cardiovascular disease. En *Circulation research, 110* (págs. 1097–1108). Obtenido de https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3366686/

Oen-Hsiao, J. (2019). *Todo sobre las enfermedades del corazón*. Obtenido de Medical News Today: https://www.medicalnewstoday.com/articles/es/327293

Okamoto, H., & Hori, M. (2012). *Heart rate as a target of treatment of chronic heart failure*. Obtenido de Journal of Cardiology: https://www.journal-of-cardiology.com/article/S0914-5087(12)00125-6/fulltext

Palatini, P., & S., J. (2004). *Elevated heart rate: a major risk factor for cardiovascular disease.* Clin Exp Hypertens.

Park, C., Guallar, E., Linton, J. A., Lee, D. C., Jang, Y., Son, D. K., . . . & Samet, J. M. (1988–1993). *Fasting glucose level and the risk of incident atherosclerotic cardiovascular diseases*. Obtenido de https://doi.org/10.2337/dc12-1577

Prohías, D. J. (2021). *Big Data en cardiología*. Obtenido de https://www.ehcos.com/big-data-y-su-impacto-en-la-cardiologia/

Sanchez-Martinez, S., Duchateau, N., Erdei, T., Kunszt, G., Aakhus, S., Degiovanni, A., . . . & Bijnens, B. H. (2018). *Machine Learning Analysis of Left Ventricular Function to Characterize Heart Failure With Preserved Ejection Fraction.* Obtenido de PubMed.gov: https://doi.org/10.1161/CIRCIMAGING.117.007138

Shouval, R., Hadanny, A., Shlomo, N., Iakobishvili, Z., Unger, R., Zahger, D., . . . & Beigel, R. (2017). Machine learning for prediction of 30-day mortality after ST elevation

myocardial infraction: An Acute Coronary Syndrome Israeli Survey data mining study. En *International journal of cardiology* (págs. 246, 7–13).

Tesche, C., Cecco, D., & Baumann, S. (10 de Abril de 2018). Coronary CT. angiography-derived fractional flow reserve: machine learning algorithm versus computational fluid dynamics modeling. *Radiology*, 288, 64-72. Obtenido de Radiology.

Toche, N. (28 de 09 de 2021). *Relación COVID-19 y enfermedades del corazón*. Obtenido de El Economista: https://www.eleconomista.com.mx/arteseideas/Existe-una-profunda-relacion-entre-enfermedades-del-corazon-y-Covid-19-20210928-0174.html

Tumolo, J. (19 de Febrero de 2015). *Typical and Atypical angina*. Obtenido de https://www.harringtonhospital.org/typical-and-atypical-angina-what-to-look-for/

Wallert, J. T. (2017). *Predicting two-year survival versus non-survival after first myocardial infarction using machine learning and Swedish national register data.* Obtenido de BMC Medical Informatics and Decision Making.

Weng, S. F., Reps, J., Kai, J., Garibaldi, J. M., & Qureshi, N. (7 de Abril de 2017). *Can machine-learning improve cardiovascular risk prediction using routine clinical data?* Obtenido de https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0174944

Yıldırım, Ö., Pławiak, P., Tan, R. S., & Acharya, U. R. (2018). Arrhythmia detection using deep convolutional neural network with long duration ECG signals. *Computers in biology and medicine*, 102, 411–420.

Zujie, G. (2019). *Gender differendes in cardiovascular disease*. Obtenido de https://doi.org/10.1016/j.medntd.2019.100025